Predicción de estrategias de neumáticos en Fórmula 1 mediante técnicas de aprendizaje automático basadas en características de carrera y condiciones climáticas

Trabajo Fin de Máster para la obtención del título de Máster en Data Science e Inteligencia Artificial

Índice

1. Introducción 1
1.1. Contexto y relevancia del sector 1
1.2. La doctrina de las ganancias marginales 1
1.3. El neumático como variable crítica de optimización estratégica 1
1.4. Hacia un nuevo paradigma: aprendizaje automático y modelado secuencial 2
2. Objetivo del trabajo 2
2.1 Objetivo general 2
2.2 Objetivos específicos 3
2.3 Pregunta de investigación 3
2.4 Enfoque metodológico general 4
3. Estado del Arte 4
3.1 Introducción 4
3.2 Modelización del neumático y degradación en Fórmula 1 5
3.3 Aprendizaje automático para la optimización estratégica 5
3.4 Modelos secuenciales y Deep Learning en competición 6
3.5 Interpretabilidad y análisis de sesgos 6
3.6 Síntesis y conexión con los objetivos 7
4. Datos y Análisis Exploratorio 7
4.1. Adquisición e ingesta de datos 7
4.2. Procesamiento y limpieza de datos 9
4.2.1. Procesamiento del Dataset principal 9
4.2.2. Procesamiento Dataset Eventos Seguridad 18
4.3. Ingeniería de características. Construcción del dataset final 20
4.4. Análisis de componentes principales PCA 21
5. Metodología del modelo 23
5.1. Consideraciones previas y justificación del enfoque 23
5.1.1. Análisis del desbalance de clases 23
5.1.2. Selección del Modelo 25
5.2. Definición de la Arquitectura del modelo 26

5.2.1. Arquitectura Multitarea (Multitask Learning) 26
5.2.2. Función de pérdida 26
5.2.3. Características del dataset y su impacto en el modelo 27
5.2.4. Rendimiento esperado y métricas empleadas 27
5.3. Preparación de Datos para el Modelo 28
5.3.1. Codificación de variables de entrada 28
5.3.2. Construcción de secuencias y padding dinámico 29
5.3.3. Generación de variables objetivo multitarea 29
5.3.4. División del conjunto de datos 29
5.4. Estrategia de Entrenamiento y Optimización 30
5.4.1. Entrenamiento Inicial (Baseline) 30
5.4.2. Optimización del Modelo 34
5.5. Evaluación de la Generalización 38
6. Resultados y Evaluación del Modelo 39
6.2. Análisis de Métricas Globales 40
6.2. Detalle de Rendimiento por Clase 40
6.2.1. Rendimiento del Modelo Inicial 40
6.2.2. Rendimiento del Modelo Final 41
6.3. Análisis de la Matriz de Confusión 42
6.4. Análisis de Errores y Limitaciones 43
6.4.1. Confusión MEDIUM vs HARD 43
6.4.2. Degradación Temporal 43
6.4.3. Falsos Positivos de Lluvia 43
6.5. Propuestas de Mejora 43
7. Interpretabilidad del Modelo 44
7.1. Explicación del Modelo 44
7.1.1. Análisis de Importancia de Características 45
7.2. Evaluación de Sesgos 46
7.2.1. Robustez Climática (Sesgo de Seguridad) 46
7.2.2. Consistencia entre Pilotos (Sesgo de Equidad) 47
8. Discusión 47

7.1. Evaluación del Enfoque Multitarea y el Aprendizaje Secuencial 47
7.2. Lógica Interna e Interpretabilidad de las Decisiones 48
7.3. Caracterización de Errores y Limitaciones del Modelo..... 48
7.4. Análisis de Sesgos y Equidad Algorítmica 49
7.5. Propuestas de Trabajo Futuro 49
8. Conclusiones 49
8.1. Respuesta a la pregunta de investigación 50
8.2. Consecución de objetivos específicos 50
8.3. Contribución a la reducción de la incertidumbre 50
8.4. Consideraciones Finales..... 51
Bibliografía 52

1. Introducción

1.1. Contexto y relevancia del sector

La Fórmula 1 representa uno de los entornos tecnológicos más avanzados en el ámbito de la ingeniería automovilística y el análisis de datos. En este contexto altamente competitivo, la excelencia técnica no se persigue mediante mejoras aisladas, sino a través de una optimización sistémica donde cada componente debe interactuar de forma eficiente y consistente. Como señala Adrian Newey, Director Técnico (Chief Technical Officer) de Red Bull Racing (2006–2025), el objetivo fundamental de la ingeniería de competición es garantizar que los elementos del monoplaza, y en particular los neumáticos, maximicen su interacción con la superficie de la pista, cuestionando continuamente cómo incrementar el rendimiento a través de mejoras marginales en la eficiencia mecánica.

1.2. La doctrina de las ganancias marginales

Bajo este paradigma de perfección técnica, la Fórmula 1 contemporánea ha evolucionado hacia un modelo de optimización extrema. En un entorno regulado por normativas técnicas estrictas impuestas por la FIA, las ventajas competitivas rara vez provienen de innovaciones disruptivas, sino de la agregación de múltiples mejoras marginales. Tal como recoge Clear (2018) sobre la metodología de Sir Dave Brailsford en el equipo British Cycling, esta filosofía se basa en la acumulación de pequeñas optimizaciones del 1% que, combinadas, generan una ventaja significativa. Esta filosofía es sintetizada por James Vowles durante su etapa como Director de Estrategia de Mercedes-AMG Petronas (2010–2022), quien destaca que la diferencia competitiva ya no reside en grandes avances estructurales, sino en la capacidad de identificar y explotar “ganancias ocultas” mediante una comprensión profunda de los datos y los procesos operativos. En este escenario, la lucha por cada milisegundo se traslada progresivamente del diseño físico a la precisión del análisis predictivo y la toma de decisiones estratégicas.

1.3. El neumático como variable crítica de optimización estratégica

Dentro de este marco, la estrategia de neumáticos constituye uno de los factores con mayor impacto potencial en el resultado de una carrera. El neumático es el único punto de contacto entre el monoplaza y el asfalto, y su comportamiento presenta una elevada complejidad termomecánica. Bajo el actual marco regulatorio, Pirelli suministra una gama limitada de compuestos con propiedades diferenciadas, lo que introduce un compromiso estratégico fundamental: los

compuestos más blandos ofrecen un mayor coeficiente de fricción y, por tanto, un rendimiento por vuelta superior, pero experimentan una degradación más rápida; en contraste, los compuestos más duros proporcionan una mayor durabilidad a costa de una reducción en el ritmo.

Desde una perspectiva estratégica, este problema es inherentemente multivariable y secuencial, ya que la elección de un compuesto en un determinado stint condiciona tanto las decisiones futuras como el rendimiento global de la carrera. En consecuencia, pequeñas mejoras en la capacidad predictiva de los modelos utilizados para apoyar la toma de decisiones pueden traducirse en ventajas tácticas significativas al finalizar la competición.

1.4. Hacia un nuevo paradigma: aprendizaje automático y modelado secuencial

Tradicionalmente, la simulación de estrategias de carrera se ha basado en modelos analíticos y estadísticos diseñados para escenarios específicos. Sin embargo, en la era del Big Data, la ventaja competitiva ya no depende exclusivamente del volumen de información disponible, sino de la metodología empleada para su procesamiento y explotación. Hannah Schmitz, Ingeniera Principal de Estrategia (Principal Strategy Engineer) de Oracle Red Bull Racing, subraya que, aunque los equipos disponen de conjuntos de datos similares, la diferencia real emerge de la forma en que dichos datos se transforman en conocimiento accionable.

En este contexto, los algoritmos de aprendizaje automático y, en particular, los modelos de aprendizaje profundo, permiten capturar relaciones no lineales y dependencias secuenciales entre variables agregadas de contexto, tales como características globales del circuito, condiciones climáticas y decisiones previas de neumáticos. Desde un punto de vista computacional, la estrategia de neumáticos puede formularse como un problema de predicción secuencial autorregresiva, en el que cada decisión influye directamente en el espacio de decisiones futuras, lo que justifica el desarrollo de metodologías capaces de aprender patrones estratégicos generalizables a partir de datos históricos y motiva el presente trabajo.

2. Objetivo del trabajo

2.1 Objetivo general

El objetivo principal de este Trabajo de Fin de Máster es desarrollar y evaluar un modelo de aprendizaje automático de naturaleza secuencial capaz de predecir estrategias de neumáticos en carreras de Fórmula 1 a partir de características

globales del circuito, condiciones climáticas y el estado dinámico de carrera, con el propósito de identificar patrones estratégicos generalizables más allá de eventos individuales.

Este enfoque busca contribuir a la reducción de la incertidumbre en la toma de decisiones estratégicas mediante el aprendizaje de secuencias históricamente eficientes, integrando información contextual y dependencias temporales propias de la dinámica de competición.

2.2 Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- Construir un conjunto de datos estructurado a nivel de stint que represente secuencias completas de estrategias de neumáticos por piloto y carrera, incorporando variables de contexto y estado dinámico de carrera.
- Realizar un análisis exploratorio de datos orientado a identificar patrones de ritmo, degradación implícita y relaciones entre compuestos, duración de stints y condiciones ambientales.
- Diseñar e implementar un modelo de aprendizaje profundo basado en redes neuronales recurrentes tipo LSTM con arquitectura multitarea para la predicción conjunta del compuesto de neumático siguiente y la duración del stint.
- Desarrollar un esquema de simulación autorregresiva de carrera que permita evaluar la coherencia estratégica de las secuencias predichas de forma completa, reproduciendo el proceso real de toma de decisiones.
- Definir métricas de evaluación específicas para problemas secuenciales, incluyendo precisión paso a paso, exactitud de secuencia completa y precisión en las fases iniciales de la estrategia de carrera.
- Analizar la interpretabilidad del modelo mediante técnicas de explicación basadas en gradientes (SHAP), identificando las características más influyentes en la predicción estratégica.
- Evaluar la presencia de posibles sesgos del modelo en distintos subgrupos de datos, tales como condiciones meteorológicas y pilotos, con el fin de analizar su robustez y generalización.

2.3 Pregunta de investigación

La investigación desarrollada en este trabajo se articula en torno a la siguiente cuestión principal:

¿En qué medida las características globales del circuito y las condiciones climáticas permiten predecir de forma coherente el rendimiento estratégico de una secuencia de neumáticos a lo largo de una carrera de Fórmula 1 mediante modelos de aprendizaje automático secuencial?

2.4 Enfoque metodológico general

El problema se aborda como una tarea de aprendizaje supervisado de naturaleza secuencial, en la que cada estrategia de neumáticos se representa como una sucesión ordenada de decisiones discretas condicionadas por el contexto de carrera y las decisiones previas.

Se emplean modelos de aprendizaje profundo basados en redes LSTM para capturar dependencias temporales entre stints, integrando variables numéricas, categóricas y binarias que describen el estado dinámico de la competición. La evaluación se diseña de forma alineada con el impacto real de las decisiones estratégicas, mediante simulaciones completas de carrera y métricas secuenciales específicas.

Este enfoque prioriza la capacidad de generalización estratégica frente al ajuste a escenarios individuales, permitiendo analizar patrones comunes de toma de decisiones bajo distintas configuraciones de circuito y condiciones ambientales.

3. Estado del Arte

3.1 Introducción

El estudio de la estrategia de neumáticos en Fórmula 1 ha evolucionado desde modelos puramente físicos de degradación hacia enfoques estadísticos avanzados y, más recientemente, técnicas de aprendizaje profundo (Deep Learning). En paralelo, el desarrollo de modelos secuenciales ha permitido capturar dependencias temporales complejas, lo que resulta especialmente relevante en contextos donde las decisiones no son eventos aislados, sino eslabones de una cadena estratégica, como ocurre en la gestión de una carrera.

Este capítulo revisa los trabajos más relevantes relacionados con la modelización del rendimiento y la toma de decisiones en Fórmula 1. El análisis parte de los enfoques clásicos de optimización y modelado físico, transita por las aplicaciones de Machine Learning estático y culmina en las arquitecturas secuenciales recientes. El objetivo es contextualizar la propuesta metodológica de este Trabajo Fin de Máster, justificando la necesidad de un modelo LSTM multitarea que integre predicción, interpretabilidad y evaluación de sesgos.

3.2 Modelización del neumático y degradación en Fórmula 1

Una parte significativa de la literatura existente se ha centrado en entender el comportamiento físico del neumático para inferir su vida útil.

Cappello y Hoegh (2023) proponen un enfoque basado en modelos de estado-espacio (State-Space Models) para representar la evolución del rendimiento del neumático vuelta a vuelta. Este tipo de aproximación permite capturar dinámicas de desgaste y variaciones en el ritmo, ofreciendo una descripción detallada del comportamiento del neumático a nivel intra-carrera.

De forma complementaria, Todd (2020) presenta un enfoque de predicción temporal centrado en la energía del neumático, incorporando técnicas explicables para interpretar la degradación. Este trabajo es relevante porque demuestra que las variables relacionadas con el estado del neumático presentan dependencias secuenciales significativas que no pueden ser ignoradas.

Sin embargo, estos modelos físicos, aunque precisos en la micro-dinámica del desgaste, no abordan explícitamente la secuencia estratégica de decisiones (cuándo parar y qué montar) bajo la incertidumbre de factores externos como el clima o la posición en pista.

3.3 Aprendizaje automático para la optimización estratégica

La transición hacia el uso de datos masivos para la toma de decisiones estratégica fue impulsada por trabajos pioneros que buscaron superar las limitaciones de las simulaciones físicas puras.

El trabajo seminal de Tulabandhula y Rudin (2014) marca un punto de inflexión en la literatura. En su estudio "On the Tire Change Decision in Formula 1 Racing", proponen un algoritmo de aprendizaje supervisado combinado con optimización estocástica para determinar el momento óptimo de la parada en boxes. Este trabajo sentó las bases teóricas para tratar la estrategia como un problema de optimización basado en datos históricos, aunque su enfoque no contemplaba la complejidad de las arquitecturas neuronales modernas.

En una línea estadística, Phillips (2014) desarrolló modelos bayesianos para la predicción de tiempos por vuelta, permitiendo inferir el ritmo de carrera ajustado por el efecto del combustible y el tráfico. Aunque eficaz para estimaciones puntuales, este enfoque carece de la flexibilidad para modelar relaciones no lineales complejas entre variables heterogéneas (clima, compuesto, desgaste).

Más recientemente, Rodríguez Pinto (2019), en su trabajo de fin de grado, explora el uso de modelos de Machine Learning clásicos (k-NN, SVM) para la predicción de resultados finales y clasificaciones. Sus resultados validan que las

variables contextuales del circuito son predictivas del rendimiento, pero su formulación permanece estática: predice el resultado final agregado, no la secuencia de decisiones que conduce a él.

Por su parte, El Haber et al. (2024) han actualizado estos enfoques empleando *Random Forest* junto con técnicas de interpretabilidad (SHAP) para analizar los factores determinantes en la victoria. Su aporte refuerza la utilidad de métodos explicables en entornos de alta complejidad, un componente que este Trabajo Fin de Máster integra en su metodología.

3.4 Modelos secuenciales y Deep Learning en competición

La limitación de los modelos anteriores para capturar la historia de la carrera ha derivado en la adopción de redes neuronales recurrentes.

Un avance significativo se observa en el trabajo de Wishal Fatima y Johrendt (2020) con su propuesta "Deep-Racing". Estos autores introducen una red neuronal profunda diseñada para predecir estrategias ganadoras, conceptualizando la carrera como una secuencia de decisiones interdependientes. Este enfoque se aproxima al adoptado en este Trabajo Fin de Máster, al reconocer que la decisión del stint (t) depende del estado en (t-1).

No obstante, la literatura existente muestra aún una brecha importante: la falta de arquitecturas multitarea capaces de predecir simultáneamente el compuesto (clasificación) y la duración del stint (regresión), así como la escasa exploración de mecanismos de atención o recurrencia (LSTM) robustos ante condiciones climáticas cambiantes y secuencias de longitud variable (Packed Sequences).

3.5 Interpretabilidad y análisis de sesgos

Finalmente, la creciente complejidad de los modelos de "caja negra" ha impulsado la necesidad de auditoría algorítmica.

Mientras que el uso de SHAP (SHapley Additive exPlanations) ha sido validado en trabajos como el mencionado de El Haber et al. para identificar variables clave, la literatura específica sobre evaluación de sesgos en modelos de Fórmula 1 es prácticamente inexistente. No existen estudios exhaustivos que analicen si los modelos estratégicos presentan un rendimiento dispar bajo condiciones de lluvia extrema o si favorecen sistemáticamente a ciertos perfiles de pilotos o equipos.

Esta carencia justifica la incorporación explícita en este Trabajo Fin de Máster de un análisis de robustez climática y consistencia entre pilotos, elevando el estándar de evaluación más allá de la simple métrica de precisión accuracy.

3.6 Síntesis y conexión con los objetivos

La revisión del estado del arte permite extraer conclusiones que fundamentan la propuesta de este trabajo:

- Evolución: Se ha pasado de la física del neumático (Cappello, Todd) y la estadística bayesiana (Phillips) al aprendizaje automático (Tulabandhula, Rodríguez Pinto).
- El Hueco Secuencial: Aunque existen aproximaciones de Deep Learning (Wishal Fatima), persiste la necesidad de modelos LSTM Multitarea autorregresivos que gestionen eficazmente la dualidad compuesto-duración.
- Auditoría del Modelo: La interpretabilidad y el análisis de sesgos son áreas críticas pero poco exploradas en la bibliografía específica de F1.

En este contexto, la metodología propuesta en este Trabajo de Fin de Máster se posiciona como una extensión natural de la literatura, integrando la potencia secuencial de las LSTM con una evaluación rigurosa de interpretabilidad y equidad algorítmica.

4. Datos y Análisis Exploratorio

4.1. Adquisición e ingesta de datos

Para el desarrollo de este estudio, la obtención de datos se ha realizado a través de la API de OpenF1, una iniciativa de código abierto que proporciona acceso democratizado a datos históricos y en tiempo real de Fórmula 1. La elección de esta fuente se justifica por su arquitectura REST y la disponibilidad de endpoints granulares que permiten reconstruir la telemetría y el contexto de carrera con una frecuencia de muestreo de aproximadamente 3.7 Hz (tabla 1).

Endpoint	Descripción
sessions	contexto del evento (país, circuito, nombre de la sesión, fecha)
stints	tipo de compuesto de neumáticos utilizado, en qué vuelta empezó/terminó y el orden del *stint*
weather	temperatura del aire, temperatura de la pista, humedad, presión y viento
laps	tiempos de vuelta detallados, sectores y si la vuelta es válida o no
drivers	nombre piloto, equipo al que pertenece
race_control	estado de la sesión, incidente de carrera, banderas, coche de seguridad

Tabla 1. Descripción de los endpoints utilizados en la API OpenF1.

La adquisición de los datos se realizó mediante el desarrollo de un script de Python encargado de ejecutar múltiples consultas a la API pública de OpenF1. A través de dichas consultas se extrajeron conjunto de datos estructurados correspondientes a pilotos, carreras, stints, resultados de carrera, paradas en boxes, eventos de safety car y virtual safety car, así como variables meteorológicas asociadas a cada evento. El periodo de estudio abarca las temporadas comprendidas entre los años 2023 y 2025.

Los datos recuperados fueron almacenados inicialmente en archivos CSV separados según el tipo de información que representan. Posteriormente, mediante el diseño y la aplicación de funciones auxiliares específicas, dichos archivos fueron transformados y cargados en estructuras DataFrame de Pandas, facilitando su manipulación, integración y análisis posterior. En la tabla 2 se describe en detalle los conjuntos de datos obtenidos a partir de la API, así como las principales características y variables contenidas en cada uno de los DataFrames resultantes.

DataFrame	Filas	Columnas	Tipos de dato	Valores nulos
df_1	3977	9	bool, int64, object	
df_sc_1	80	5	float64, int64, object	end_lap 12

Tabla 2. Características DataFrames.

Variables clave en df_1

- race_id: Identificador único de carrera.
- driver_id: Identificador único de piloto.
- circuit: Nombre del circuito.
- race_year: Año en que se disputa el evento.
- stint_number: Conjunto de vueltas consecutivas completadas por el piloto con el mismo juego de neumáticos.
- lap_start: Número de la vuelta inicial del stint.
- lap_end: Número de la última vuelta completada en el stint.
- current_tyre: Tipo de neumático utilizado en el stint.
- rain: Presencia de lluvia durante el evento.

Variables clave en df_sc_1

- circuit: Nombre corto o habitual del circuito donde se realiza el evento.
- race_year: Año en que se disputa el evento.
- start_lap: Número de la vuelta en la que comienza el evento.
- end_lap: Número de la vuelta en la que finaliza el evento.
- type: Tipo de evento; puede ser SC (SafetyCar) o VSC (Virtual Safety Car).

4.2. Procesamiento y limpieza de datos

Con el objetivo de procesar y preparar los datos obtenidos para su posterior análisis y modelado, se aplicó de manera sistemática el siguiente esquema de trabajo a cada uno de los DataFrames:

- Exploración inicial mediante análisis descriptivo de variables numéricas y categóricas.
- Transformación y limpieza de datos incluyendo tratamiento de valores nulos, eliminación de registros inconsistentes, ajuste de tipos de datos, detección y gestión de outliers y duplicados.
- Ingeniería de características (feature engineering).
- Integración de datasets mediante la combinación de los distintos conjuntos de datos en estructuras consolidadas.
- Análisis orientado al contexto del negocio y a la estrategia de carrera.

En las siguientes secciones se detalla la implementación específica de estas etapas en cada uno de los conjuntos de datos analizados.

4.2.1. Procesamiento del Dataset principal

El DataFrame df_1 cuenta con 3977 filas y 9 columnas. Todas las variables tienen el tipo de dato adecuado. No contiene campos vacíos o nulos. La detección de duplicados se realizó empleando una clave lógica compuesta por race_id, driver_id y stint_number, al representar de forma única cada stint de neumáticos por piloto y carrera. No se evidenció la presencia de registros repetidos en el conjunto de datos.

4.2.1.1. Análisis inicial de variables numéricas

En la figura 1 se observa que los valores extremos detectados en la variable race_id no corresponden a anomalías reales, sino a identificadores asignados secuencialmente por la API de OpenF1 para eventos más tempranos dentro del periodo de estudio, en concreto, 2023.

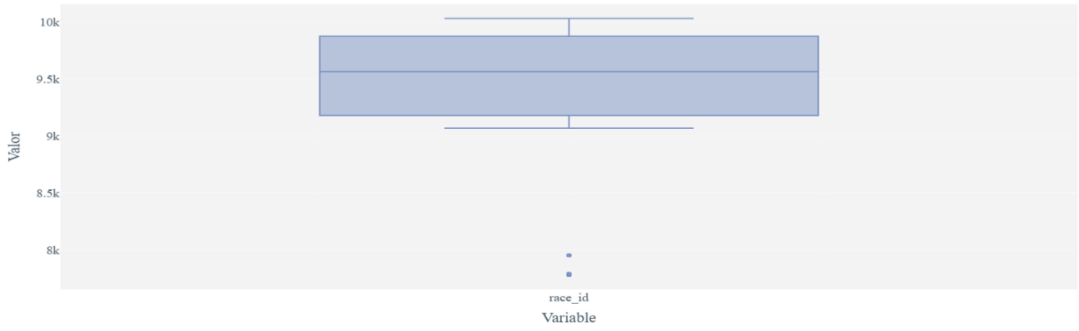

Figura 1. Valores mínimos extremos de la variable race_id

Dado que race_id actúa como clave identificadora y no como variable cuantitativa con significado físico, estos valores no fueron tratados como outliers ni eliminados del conjunto de datos.

El análisis conjunto de las variables stint_number, lap_start y lap_end, mostrado en la figura 2, permite caracterizar la estructura temporal de las estrategias de carrera.

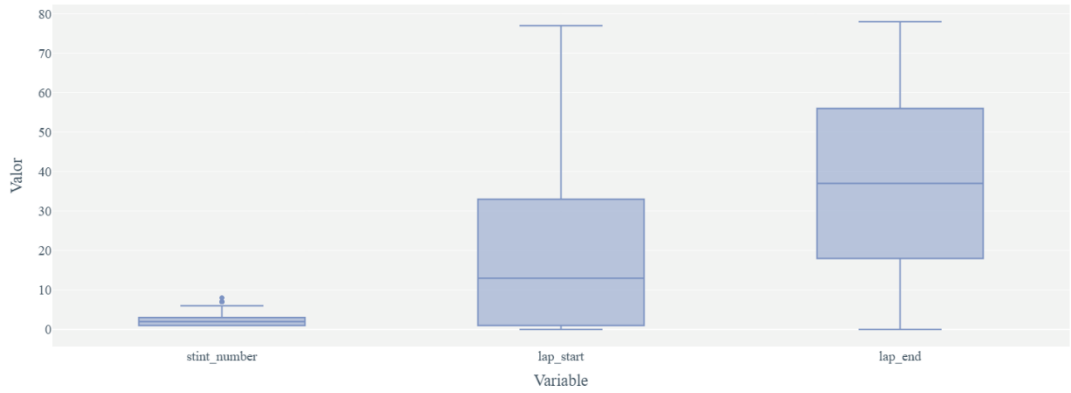

Figura 2. Distribución de las variables stint_number, lap_star y lap_end.

La mayoría de los pilotos realizan entre uno y tres stints por evento, con una mediana de dos, en línea con las estrategias habituales en Fórmula 1 (figura 3).

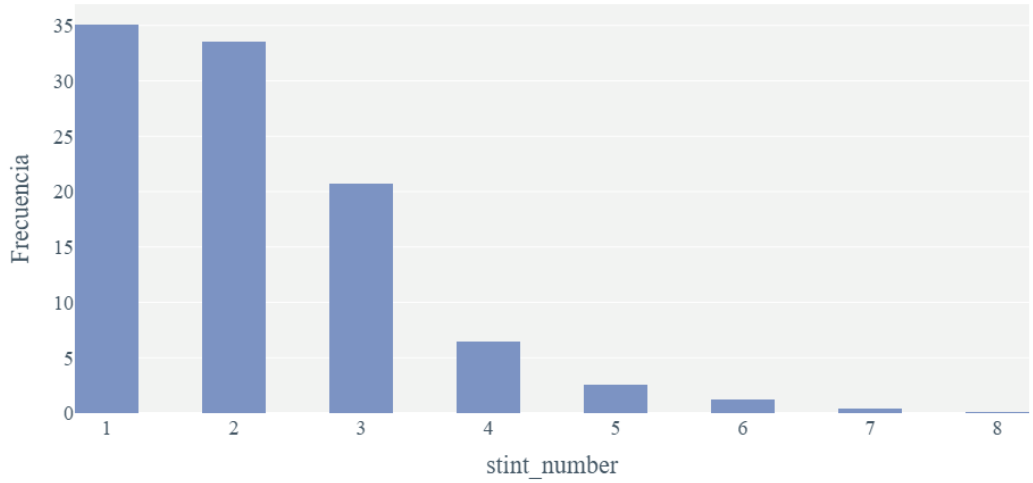

Figura 3. Distribución de las frecuencias de la variable stint_number.

El análisis de la variable lap_start mediante diagrama de caja (figura 2) e histograma de frecuencias (figura 4) muestra una distribución claramente asimétrica positiva, con una elevada concentración de stints iniciados en las primeras vueltas de carrera (mediana en la vuelta 13 y primer cuartil en la vuelta 1), y una cola prolongada hacia valores elevados. Este comportamiento refleja que la

mayoría de las estrategias comienzan con stints tempranos, mientras que los inicios tardíos suelen estar asociados a paradas inducidas por eventos de carrera o ajustes estratégicos.

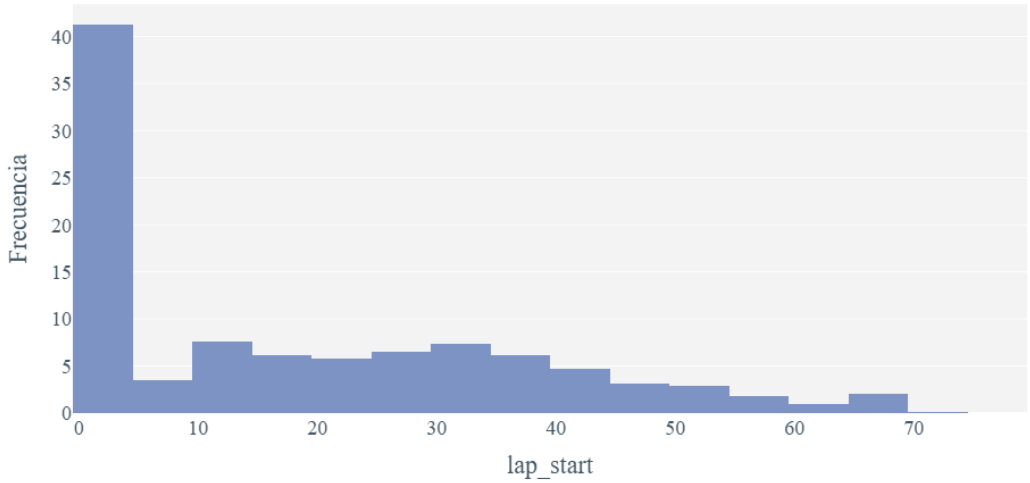

Figura 4. Histograma de la variable lap_start.

La variable lap_end presenta una distribución más progresiva a lo largo de la carrera, con una mediana situada en la vuelta 37 y una amplia dispersión hasta las últimas vueltas del evento. Tanto el diagrama de caja como el histograma (figura 5) evidencian cómo los stints finalizan de forma escalonada conforme avanza la prueba, coherente con la gestión de degradación de neumáticos y las ventanas de parada en boxes.

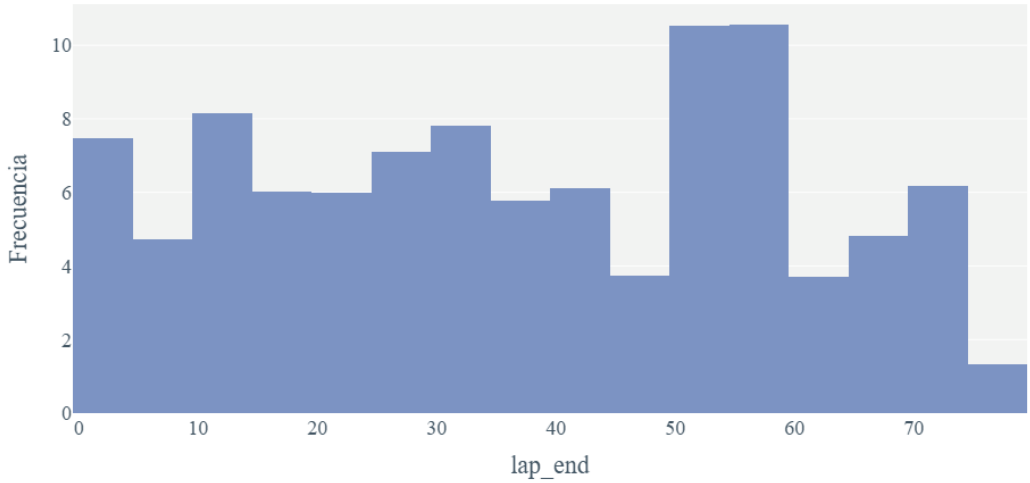

Figura 5. Histograma de la variable lap_end.

Este patrón es consistente con la dinámica de degradación de neumáticos y las ventanas estratégicas propias de la Fórmula 1, y confirma la coherencia temporal de las variables que describen la estructura de cada estrategia de carrera.

Aunque se observan valores extremos superiores en estas tres variables, estos no se consideran outliers anómalos desde el punto de vista operativo, sino manifestaciones de situaciones de carrera excepcionales pero válidas, como cambios meteorológicos, intervenciones de safety car o virtual car o incidencias técnicas, por lo que se conservan para el análisis posterior.

4.2.1.2. Análisis inicial de variables categóricas

El análisis de las características categóricas permite evaluar la representatividad del conjunto de datos y comprender los principales escenarios estratégicos presentes en las carreras de Fórmula 1. Estas variables capturan tanto el contexto competitivo, circuito y temporada, como decisiones técnicas fundamentales relacionadas con la elección de neumáticos y las condiciones meteorológicas, factores determinantes en la planificación de estrategias de carrera.

En primer lugar, se analiza la distribución de observaciones por circuito, representada mediante un diagrama de barras horizontales por frecuencia (figura 6). Esta visualización muestra la presencia de 25 trazados distintos, lo que garantiza una cobertura amplia de configuraciones de pista con diferentes niveles de degradación, longitudes de vuelta y características globales. La diversidad de circuitos resulta esencial para el objetivo del estudio, ya que permite modelar estrategias de neumáticos de forma generalista e independiente del trazado específico, evitando sesgos hacia condiciones particulares.

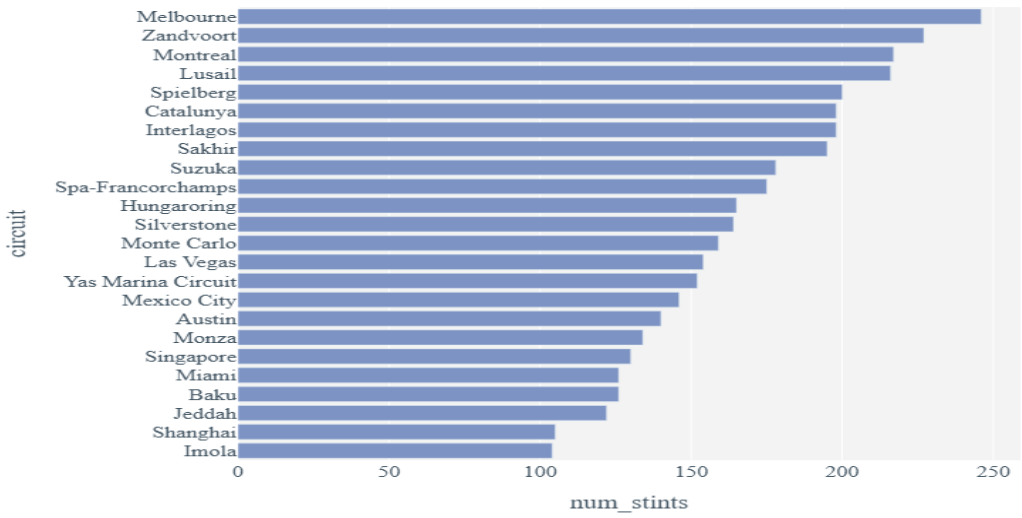

Figura 6. Distribución de las frecuencias de los circuitos comprendidos entre las temporadas 2023 a 2025.

A continuación, se examina la distribución de los compuestos de neumáticos utilizados a lo largo de los stints, representada mediante un histograma de frecuencias relativas (figura 7). Los resultados evidencian un claro predominio de neumáticos de seco, con una mayor utilización de los compuestos MEDIUM (38%) y HARD (36%), seguidos por SOFT (17%). Por su parte, los compuestos INTERMEDIATE representan aproximadamente el 8% de los casos, mientras que los neumáticos de lluvia extrema (WET) y registros clasificados como UNKNOWN presentan una frecuencia residual.

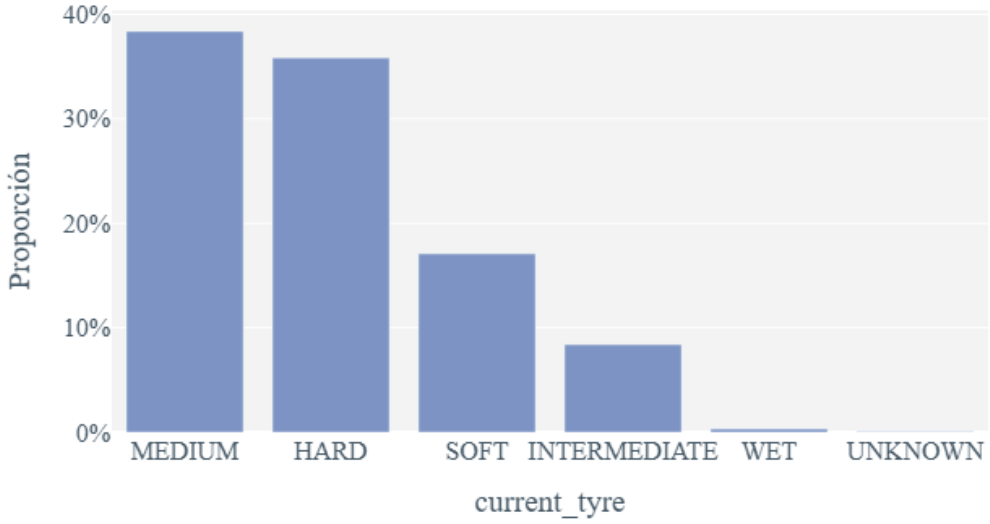

Figura 7. Histograma de frecuencias uso de neumáticos en cada stint.

Esta distribución refleja la realidad competitiva de la Fórmula 1, donde la mayoría de las estrategias se desarrollan en condiciones de pista seca, reservándose los compuestos de lluvia para situaciones excepcionales. Desde el punto de vista del modelado, este comportamiento implica un desbalance natural entre escenarios de seco y mojado, aspecto relevante a considerar en la fase de entrenamiento del modelo secuencial.

Por último, se analiza la variable meteorológica binaria que indica la presencia de lluvia durante cada stint (figura 8). Los resultados muestran que aproximadamente el 88% de las observaciones corresponden a condiciones secas, mientras que solo un 12% se desarrollan bajo lluvia. Esta proporción confirma que las situaciones de carrera en mojado constituyen eventos poco frecuentes, aunque estratégicamente críticos debido a su impacto directo en la elección de neumáticos, el número de paradas y la duración de los stints.

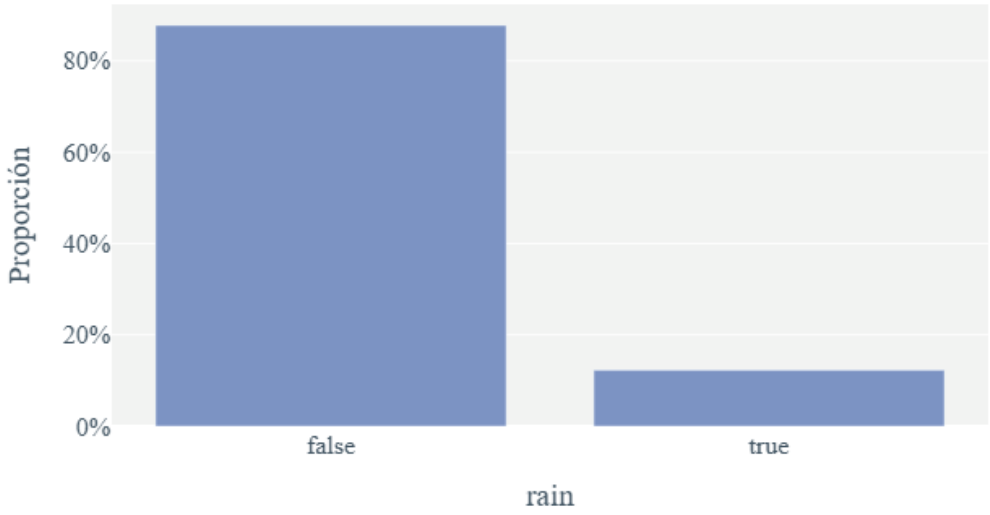

Figura 8. Distribución días de lluvia durante los Grandes Premios.

En conjunto, el análisis de las variables categóricas pone de manifiesto que el dataset captura de forma realista la diversidad de escenarios estratégicos presentes en la Fórmula 1. La amplia variedad de circuitos permite generalizar patrones de estrategia, mientras que la distribución de compuestos y condiciones meteorológicas refleja las decisiones reales de carrera. Esta información resulta fundamental para el posterior modelado secuencial mediante redes LSTM, ya que define el contexto en el que se generan las secuencias de stints y condiciona las transiciones estratégicas entre compuestos.

4.2.1.3. Ingeniería de características (feature engineering)

Con el objetivo de enriquecer la representación de las estrategias de carrera y capturar de forma explícita la dinámica temporal de los stints, se llevó a cabo un proceso de ingeniería de características sobre el conjunto de datos original. Este proceso permitió incorporar información clave relacionada con la duración de cada fase estratégica, el progreso de la carrera, el historial de decisiones de neumáticos y el número total de paradas en boxes.

Posteriormente, se realizó un análisis exploratorio de las variables generadas con el fin de evaluar su coherencia estratégica y su consistencia dentro del contexto competitivo. Esta validación se centró en la duración de los stints, la evolución temporal de la carrera y la estructura de paradas, confirmando que las características construidas representan de forma realista la dinámica de las estrategias de neumáticos en Fórmula 1.

En primer lugar, se calculó la longitud de cada stint a partir de las vueltas de inicio, lap_start y vueltas de final, lap_end, generando una nueva variable numérica, stint_length, que representa el número de vueltas completadas con un mismo juego de neumáticos. Esta variable proporciona una medida directa de la duración efectiva de cada fase estratégica y resulta fundamental para analizar patrones de degradación y planificación de paradas (figura 9).

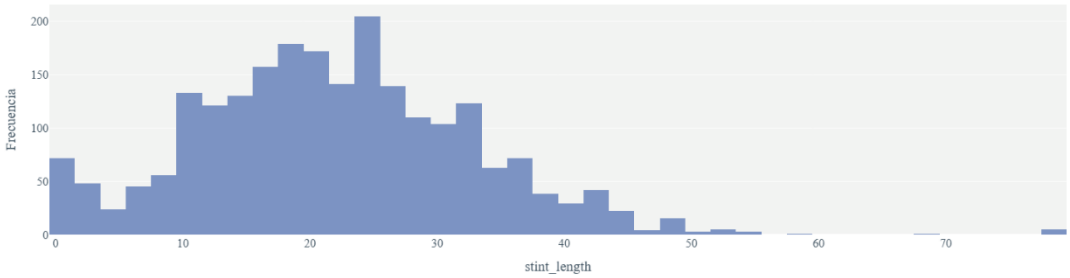

Figura 9. Distribución de la duración en vueltas de cada stint.

La visualización muestra una amplia variabilidad en la duración de los stints, con una concentración principal en valores intermedios y una presencia decreciente de stints extremadamente largos o cortos. Este comportamiento es coherente con la práctica competitiva, donde las estrategias buscan equilibrar degradación del neumático y número de paradas, validando así la consistencia de la variable generada.

Posteriormente, los registros con compuesto de neumático indeterminado fueron imputados asignando el valor MEDIUM. Esta decisión se fundamenta en que el compuesto medio representa una opción intermedia ampliamente utilizada en condiciones estándar de carrera, permitiendo evitar la pérdida de observaciones y mantener coherencia estratégica en el conjunto de datos.

Se evaluó la relación entre la duración de los stints y el compuesto de neumático utilizado (figura 10). Los diagramas de caja evidencian patrones diferenciados entre compuestos, observándose stints más prolongados asociados a neumáticos duros (HARD), seguidos por los medios (MEDIUM), mientras que los blandos (SOFT) tienden a emplearse en fases más cortas de carrera. Los compuestos intermedios presentan una mayor dispersión, reflejando la variabilidad propia de condiciones meteorológicas cambiantes. Estos resultados confirman que la variable *stint_length* captura adecuadamente la lógica estratégica asociada a cada tipo de neumático.

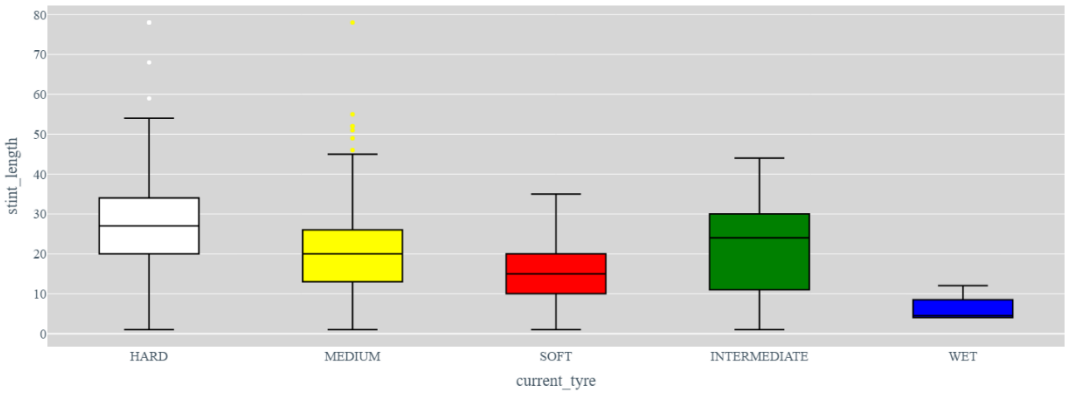

Figura 10. Diagrama de cajas de duración de cada stint por tipo neumático.

A continuación, se estimó el número total de vueltas de cada carrera mediante la identificación de la vuelta máxima registrada por circuito y temporada. Esta información se integró en el dataset para calcular las vueltas restantes en cada stint, generando una nueva característica, laps_remaining, que cuantifica el progreso relativo de la carrera en el momento de cada decisión estratégica. Esta variable resulta especialmente relevante para el modelado secuencial, ya que las decisiones de neumáticos dependen de forma directa de la distancia restante hasta el final de la prueba.

Se analizó el progreso de carrera mediante la relación entre el número de stint y las vueltas restantes hasta el final de la prueba (figura 11). Las visualizaciones muestran una clara tendencia decreciente de las vueltas restantes conforme avanza el número de stint, lo que confirma la coherencia temporal del dataset y la correcta construcción de la variable *laps_remaining*. Este patrón refleja la estructura secuencial natural de las estrategias de carrera, aspecto fundamental para su posterior modelado mediante redes neuronales recurrentes.

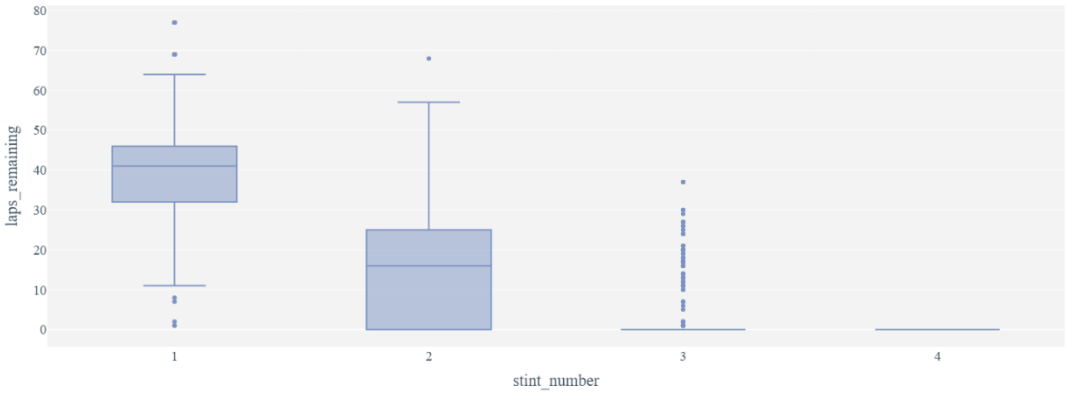

Figura 11. Diagrama de cajas del progreso de carrera entre stint_number y número vueltas restantes.

Con el fin de capturar la dependencia temporal de las estrategias, se construyó una característica secuencial que recoge el historial de neumáticos utilizados por cada piloto a lo largo de una carrera. Para cada stint, se genera una lista acumulativa que representa los compuestos empleados hasta ese momento, permitiendo al modelo aprender patrones de transición entre neumáticos y secuencias estratégicas típicas, aspecto clave para su posterior uso en redes LSTM.

Finalmente, se calculó el número total de paradas en boxes realizadas por cada piloto en cada carrera a partir del número máximo de stints observados. Con el objetivo de eliminar comportamientos excepcionalmente atípicos que podrían distorsionar el aprendizaje del modelo, se filtraron los registros correspondientes a estrategias con más de cuatro stints, considerándolos casos anómalos desde el punto de vista estratégico.

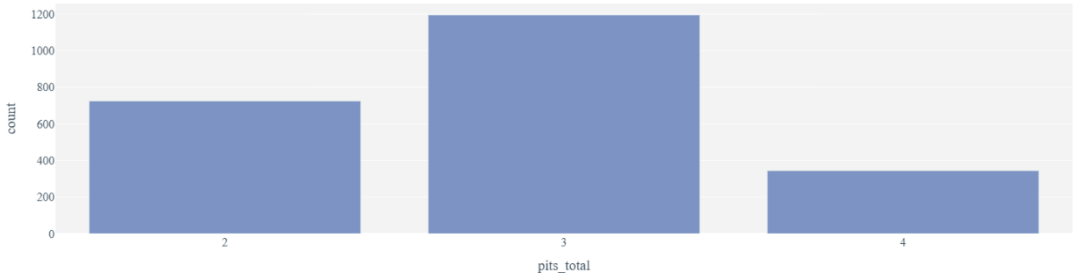

Figura 12. Distribución del número total de paradas por carrera.

Los resultados del análisis de la distribución del número total de paradas en boxes indican que la mayoría de las estrategias se concentran en uno, dos o tres cambios de neumáticos, siendo menos frecuentes las estrategias con un mayor número de paradas. Esta distribución valida el criterio aplicado para filtrar comportamientos atípicos y confirma que el dataset final se centra en patrones estratégicos representativos de la competición real.

La variable resultante, pits_total, correspondiente al número total de paradas en boxes, se integró como una característica adicional que describe la estructura de parada en boxes de cada estrategia de carrera.

En conjunto, este proceso de ingeniería de características permitió transformar los datos brutos de stints en una representación enriquecida que incorpora información temporal, estratégica y contextual, sentando las bases para el posterior entrenamiento de modelos secuenciales orientados a la predicción de estrategias óptimas de neumáticos en Fórmula 1.

4.2.2. Procesamiento Dataset Eventos Seguridad

El DataFrame df_sc_1 consta de 80 filas y 5 columnas. Todas las variables tienen el tipo de dato adecuado. Se detectan 12 valores nulos en la variable end_lap.

4.2.2.1. Análisis inicial de variables numéricas

El análisis de las variables numéricas start_lap y end_lap asociadas a la aparición del Safety Car y Virtual Safety Car muestra una elevada dispersión en el momento de intervención a lo largo de la carrera, con valores que abarcan desde las primeras vueltas hasta fases finales del gran premio. Tanto start_lap como end_lap presentan medianas en torno a la vuelta 18, indicando que estos eventos tienden a concentrarse ligeramente en el primer tercio de carrera, aunque con una distribución amplia que refleja su naturaleza impredecible.

Los rangos intercuartílicos se sitúan aproximadamente entre las vueltas 5 y 33, lo que evidencia que la mayoría de neutralizaciones ocurren en fases tempranas e intermedias, momentos especialmente relevantes desde el punto de vista estratégico al coincidir con ventanas habituales de parada en boxes. Los valores máximos, cercanos a la vuelta 70, confirman que estos eventos también pueden producirse en fases finales, aunque con menor frecuencia.

La figura 13 no sugiere la presencia de valores atípicos estructurales, sino una variabilidad esperable inherente a eventos de carrera exógenos. En conjunto, estas variables capturan adecuadamente el carácter aleatorio pero estratégicamente influyente de las neutralizaciones, justificando su inclusión como predictores en el modelado de estrategias de neumáticos, dado su impacto directo en la decisión del momento óptimo de parada y en la reconfiguración de la secuencia de stints.

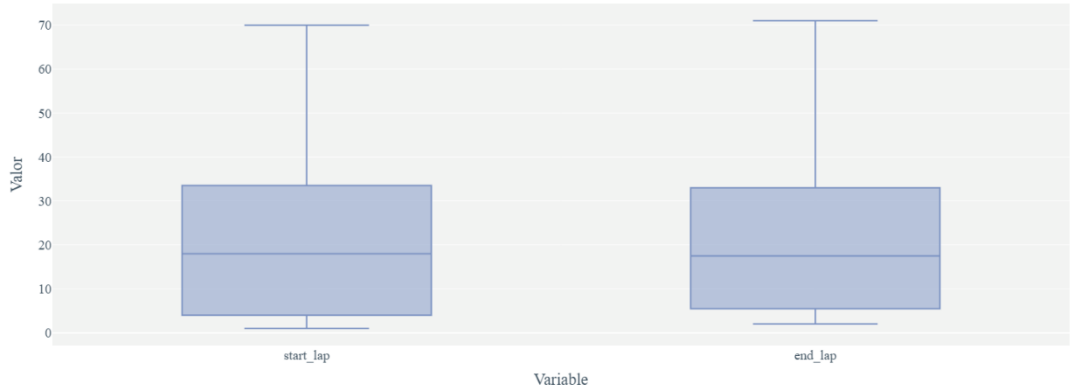

Figura 13. Distribución de las variables numéricas start_lap y end_lap.

4.2.2.2. Análisis inicial variables categóricas

El análisis por circuito revela una distribución heterogénea de los eventos de neutralización, observándose pistas con alta recurrencia tanto de Safety Car como de Virtual Safety Car, frente a otras donde su aparición es marginal (figura 14). Asimismo, se aprecian diferencias en el tipo predominante de neutralización según el trazado, lo que sugiere que las características del circuito influyen en la probabilidad y naturaleza de las interrupciones de carrera. Esta variabilidad refuerza la relevancia del circuito como variable contextual clave en la modelización de estrategias de neumáticos, dado el impacto directo que estos eventos tienen sobre las decisiones de parada en boxes y la duración de los stints.

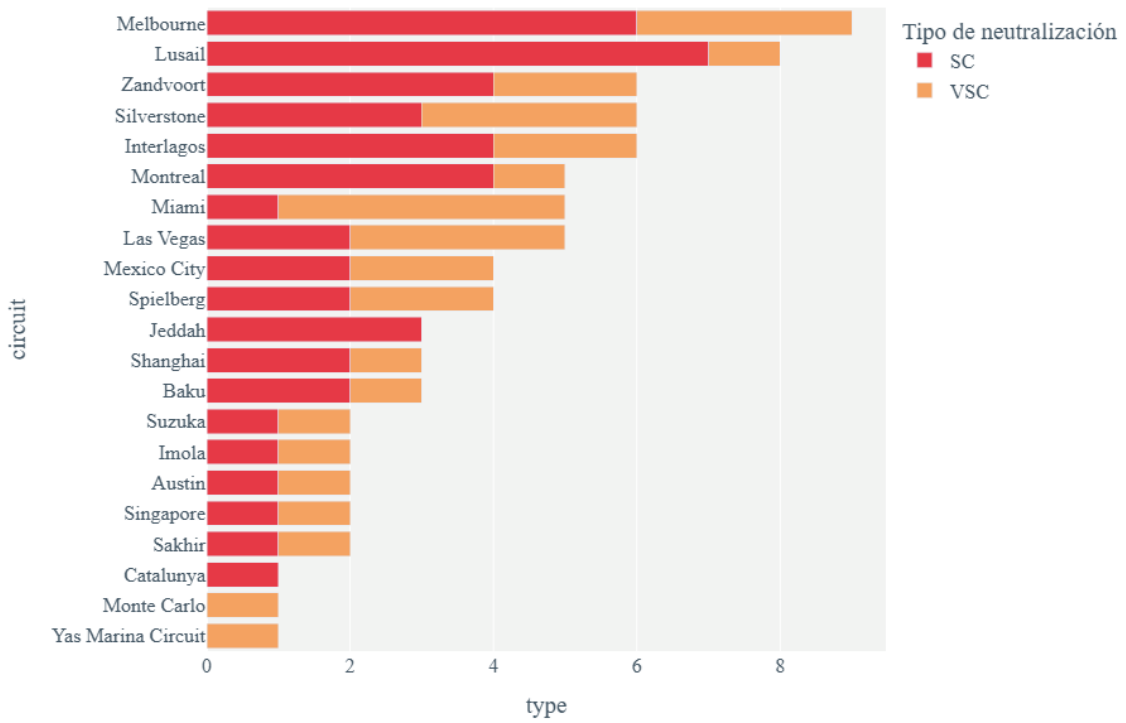

Figura 14. Número de eventos por circuito.

4.2.2.3. Gestión de valores nulos

Durante el procesamiento del conjunto de datos correspondiente a eventos de Safety Car (SC) y Virtual Safety Car (VSC), se detectaron valores nulos en la variable end_lap, que representa la vuelta de finalización de cada periodo de neutralización.

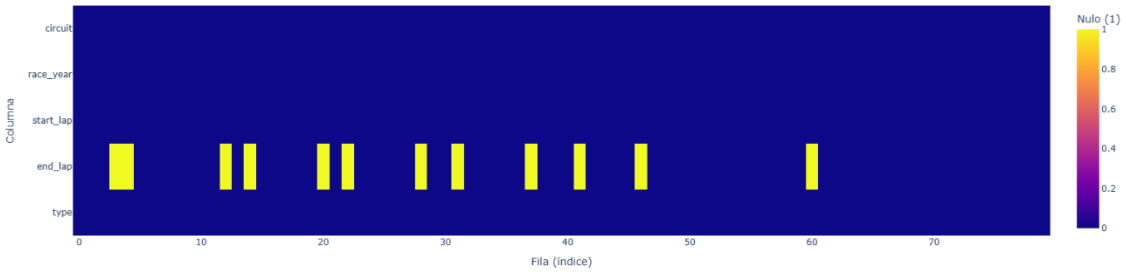

Figura 15. Mapa de valores nulos por columna/registro.

Desde un punto de vista operativo, dichos valores no corresponden a errores de captura, sino a situaciones en las que el evento de neutralización se mantuvo activo hasta el final de la carrera. Para preservar la coherencia temporal de estos registros, se integró información adicional relativa al número total de vueltas de cada carrera (total_laps), previamente calculada a partir del dataset de stints.

Mediante una operación de combinación por circuito y temporada (circuit, race_year), se asignó como valor de cierre (end_lap) el total de vueltas de la carrera en aquellos casos donde dicho campo era nulo. Posteriormente, se eliminó la variable auxiliar empleada en la imputación y se verificó la ausencia de valores faltantes en el dataset resultante.

Este enfoque permite conservar eventos válidos de neutralización sin introducir sesgos artificiales ni eliminar observaciones relevantes, asegurando una representación fiel de la duración efectiva de los periodos de SC y VSC.

4.3. Ingeniería de características. Construcción del dataset final

A partir de los conjuntos de datos procesados y enriquecidos mediante ingeniería de características, se construyó un dataset estratégico final estructurado por stints de carrera, df_final, que constituye la base para el modelado secuencial de estrategias de neumáticos.

En primer lugar, se integró la información correspondiente a eventos de Safety Car (SC) y Virtual Safety Car (VSC) procedente del DataFrame df_sc_1, asignando a cada stint variables binarias que indican si durante su desarrollo se produjo algún periodo de neutralización. Esta integración se realizó comparando los intervalos de vueltas de cada stint con los rangos temporales de los eventos de carrera, permitiendo capturar de forma explícita el impacto de interrupciones sobre la duración de los neumáticos y las decisiones estratégicas. La inclusión de estas variables se justifica por su influencia directa en la degradación, las ventanas óptimas de parada en boxes y la reconfiguración de las estrategias de carrera, tal como se evidenció en el análisis exploratorio de los eventos de neutralización

Posteriormente, se procedió a la depuración de secuencias incompletas correspondientes a pilotos que no finalizaron la carrera debido a averías, accidentes o descalificaciones. Para ello, se identificaron aquellas agrupaciones por piloto, circuito y temporada cuyo número mínimo de vueltas restantes no alcanzaba cero, eliminándose dichos registros. Esta decisión garantiza que cada secuencia temporal represente una carrera completa, condición fundamental para el entrenamiento coherente de modelos secuenciales como redes LSTM.

El dataset final incluye, para cada stint, las siguientes variables clave: identificadores de carrera y piloto, temporada, número de stint, compuesto de neumático actual, duración del stint, vueltas restantes hasta el final de la prueba, presencia de SC y VSC, condición de lluvia y el historial acumulado de neumáticos utilizados. Esta representación permite describir de forma realista el estado estratégico de cada piloto en cada punto de decisión durante la carrera.

Con el objetivo de introducir conocimiento estratégico implícito en el modelo, se desarrollaron características adicionales orientadas a capturar la viabilidad de finalizar la carrera con el neumático actual. En concreto, se calculó para cada carrera y compuesto la mediana histórica de duración de los stints, generando una referencia empírica de la vida útil típica de cada neumático en cada circuito. A partir de esta información se definió la variable booleana can_finish, que indica si el número de vueltas restantes es inferior o igual a dicha duración mediana, proporcionando al modelo una estimación del margen operativo del compuesto en uso.

Así mismo, se incorporó la variable is_final_stint, que identifica explícitamente el último stint de cada carrera, permitiendo al modelo aprender patrones asociados a la fase final de las estrategias de neumáticos.

En conjunto, este proceso dio lugar a un dataset secuencial enriquecido que combina información temporal, contextual y estratégica, reproduciendo de forma fiel la dinámica real de las decisiones de neumáticos en Fórmula 1.

4.4. Análisis de componentes principales PCA

El análisis de componentes principales aplicado al dataset final, permitió identificar dimensiones latentes relevantes en los stints de carrera.

Las tres primeras componentes explican aproximadamente el 59.1% de la varianza total. La primera componente captura la progresión temporal de la carrera, dominada por variables como las vueltas restantes, el número de stint y las variables estratégicas asociadas al final de carrera. La segunda componente refleja diferencias contextuales entre circuitos y temporadas, mientras que la tercera componente está fuertemente influenciada por la presencia de periodos de Safety

Car y Virtual Safety Car, junto con la duración de los stints, poniendo de manifiesto el impacto de neutralizaciones sobre las decisiones estratégicas (figura 16).

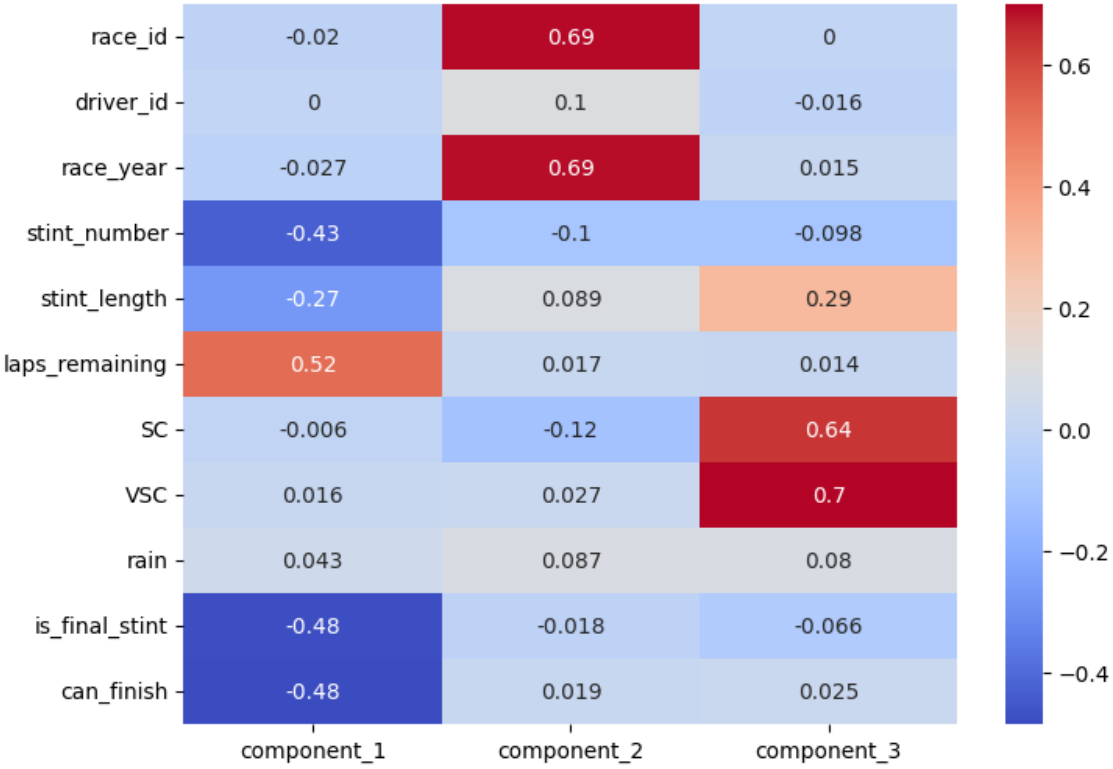

Figura 16. Heatmap PCA loadings por variable y componente.

Como análisis adicional, se realizó una validación de la coherencia secuencial del dataset final.

El número de stints por carrera presenta un valor mínimo de 2, una media de 2.67 y un máximo de 4, valores coherentes con las estrategias modernas de Fórmula 1. Asimismo, aproximadamente el 30.1% de los stints se ven afectados por periodos de Safety Car y el 18.5% por Virtual Safety Car, confirmando su relevancia estratégica sin dominar el conjunto de datos.

Finalmente, se verificó que cada secuencia contiene exactamente un stint final y que la variable de vueltas restantes decrece de forma monótona en todas las carreras, garantizando una estructura temporal consistente. En conjunto, estos resultados confirman que el dataset presenta tanto estructura multivariante latente como coherencia secuencial, justificando su idoneidad para el entrenamiento de modelos LSTM orientados a la predicción de estrategias óptimas de neumáticos.

5. Metodología del modelo

5.1. Consideraciones previas y justificación del enfoque

5.1.1. Análisis del desbalance de clases

Con el objetivo de evaluar el comportamiento de la variable objetivo y detectar posibles problemas de desbalance de clases, se analizó la distribución de los compuestos de neumáticos utilizados en el conjunto de datos. La variable current_tyre representa el tipo de neumático empleado en cada stint de carrera, constituyendo una variable categórica multiclase fundamental para el entrenamiento del modelo secuencial.

El análisis exploratorio reveló un claro dominio de los compuestos de seco, particularmente los neumáticos MEDIUM y HARD, mientras que los compuestos de lluvia, INTERMEDIATE y WET, aparecen con una frecuencia significativamente menor (figura 17).

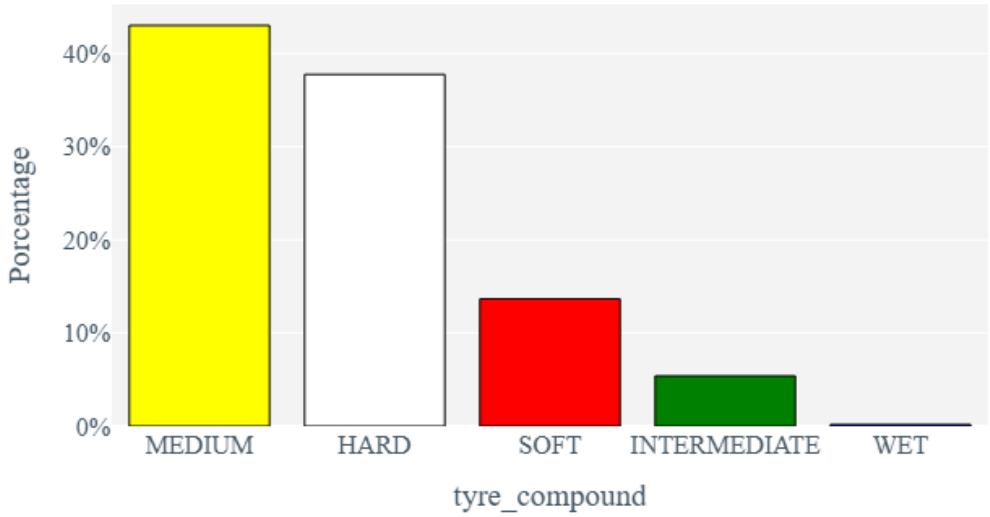

Figura 17. Distribución del tipo de neumático utilizado.

Este comportamiento refleja la realidad competitiva de la Fórmula 1, donde la mayoría de las carreras se desarrollan en condiciones secas, y los eventos de lluvia son relativamente poco frecuentes (figura 18).

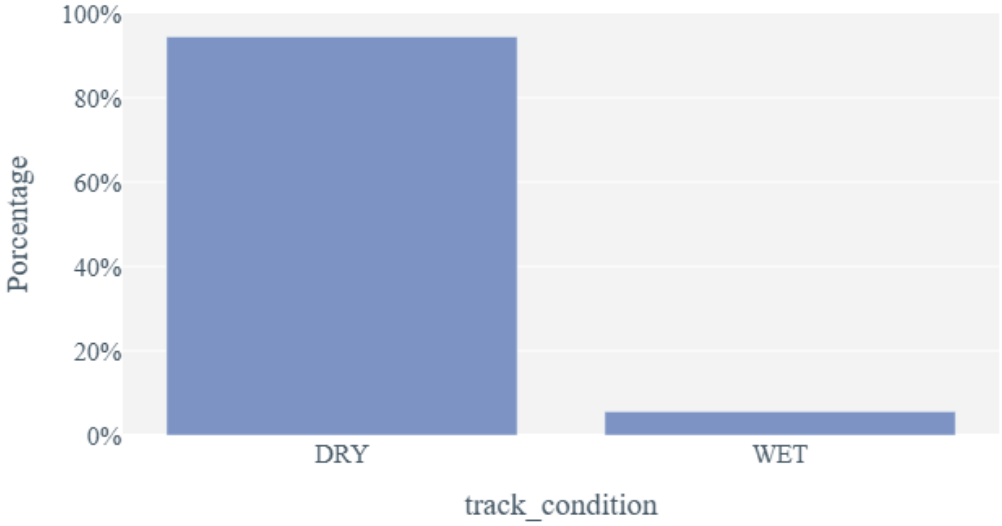

Figura 18. Distribución de condiciones de pista.

No obstante, desde el punto de vista del aprendizaje automático, esta distribución introduce un marcado desbalance entre clases, lo cual puede provocar que el modelo tienda a favorecer las clases mayoritarias, reduciendo su capacidad para predecir correctamente eventos menos frecuentes pero estratégicamente relevantes, como el uso de neumáticos de lluvia.

Además, el análisis por posición secuencial de stint mostró una clara dependencia temporal en el uso de compuestos, observándose patrones estratégicos consistentes como el empleo de neumáticos más blandos SOFT en las fases iniciales de carrera y compuestos más duros HARD en los stints finales (figura 19). Esta estructura temporal refuerza la idoneidad del uso de modelos recurrentes como LSTM para capturar la dinámica de la estrategia de neumáticos.

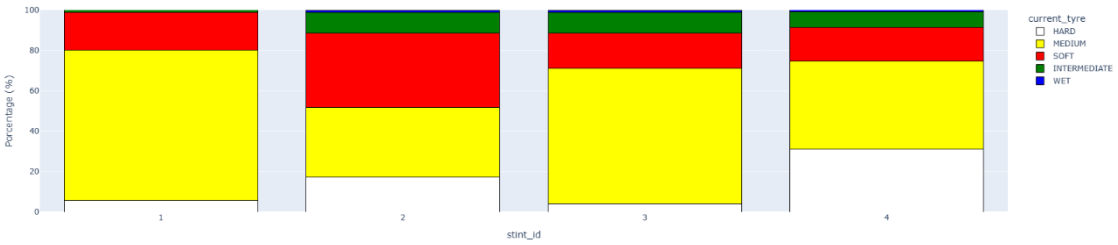

Figura 19. Evolución de la estrategia de neumáticos por stint.

Con el fin de mitigar los efectos negativos del desbalance de clases durante el entrenamiento del modelo, se implementó una estrategia de ponderación manual integrada directamente en la función de pérdida. Se definieron pesos

específicos para cada clase basados en la distribución empírica de los datos (figura 1), asignando coeficientes mayores a las clases minoritarias (como los neumáticos de lluvia WET e INTERMEDIATE) y menores a las clases mayoritarias. Esta técnica permite penalizar con mayor intensidad los errores en las categorías menos frecuentes, evitando que el modelo sesgue sus predicciones hacia los compuestos dominantes (HARD/MEDIUM). Se optó por definir estos valores manualmente debido a que el cálculo automático estricto (basado en el inverso puro de la frecuencia) a veces genera pesos demasiado extremos para clases muy raras, lo cual puede desestabilizar el entrenamiento; de este modo, los pesos manuales permitieron 'suavizar' dicha penalización para lograr una convergencia más estable. Estos valores fueron convertidos a tensores y utilizados en la función de pérdida durante el entrenamiento de la red neuronal.

Esta aproximación permite que el modelo no se limite a optimizar su rendimiento sobre los compuestos más frecuentes, sino que aprenda de forma más equitativa los patrones asociados a neumáticos menos comunes, como INTERMEDIATE y WET, mejorando así la capacidad de generalización del sistema en condiciones de carrera variables.

El análisis de clases pone de manifiesto que la predicción de estrategias de neumáticos en Fórmula 1 constituye un problema multiclase altamente desbalanceado y con fuerte dependencia temporal. La combinación de distribución no uniforme de compuestos, estructura secuencial de stints, y variabilidad condicionada por factores externos como clima y características de pista justifica plenamente el uso de modelos recurrentes junto con técnicas de corrección de desbalance.

5.1.2. Selección del Modelo

La Fórmula 1 constituye un proceso estocástico con fuerte dependencia temporal. La decisión estratégica de selección de neumáticos en una vuelta determinada no depende únicamente del estado instantáneo del monoplaza, sino del desarrollo previo de la carrera, incluyendo el historial de compuestos utilizados, el número de paradas realizadas y la evolución del ritmo.

Los modelos tradicionales de aprendizaje automático, como Random Forest o Máquinas de Soporte Vectorial, tratan cada observación de forma independiente. Sin embargo, en el presente dataset, los datos se organizan naturalmente como secuencias de stints por piloto y carrera, lo que exige un enfoque capaz de modelar dependencias temporales.

Se ha seleccionado una arquitectura basada en redes Long Short-Term Memory (LSTM), implementada mediante nn.LSTM, por dos motivos fundamentales. En primer lugar, su mecanismo de memoria interna permite

mantener información relevante a largo plazo, logrando que las decisiones tempranas condicionen las predicciones posteriores. En segundo lugar, su flexibilidad permite procesar secuencias de longitud variable, dado que las carreras presentan distinto número de paradas, mediante el uso de padding dinámico (pad_sequence) durante el entrenamiento por lotes (batches).

5.2. Definición de la Arquitectura del modelo

5.2.1. Arquitectura Multitarea (Multitask Learning)

Durante el diseño del sistema se determinó que la predicción aislada del compuesto resulta insuficiente desde el punto de vista estratégico, ya que una estrategia completa se define por la dupla compuesto + duración.

Para abordar esta dualidad, se ha diseñado una red neuronal con dos cabezales de salida (Two-Headed Architecture) que comparten un extractor común de características basado en la capa LSTM mencionada anteriormente. Este enfoque de aprendizaje multitarea (Multitask Learning) se estructura de la siguiente manera:

- Cabezal de clasificación (fc_tyre): capa lineal optimizada mediante CrossEntropyLoss para predecir la probabilidad de cada categoría de neumático (SOFT, MEDIUM, HARD, INTERMEDIATE y WET).

- Cabezal de regresión (fc_laps): capa lineal paralela optimizada con Mean Squared Error (MSE) para estimar la variable continua correspondiente a la duración del stint.

Este enfoque multitarea actúa como regularización estructural, debido a que fuerza al modelo a aprender representaciones latentes que expliquen simultáneamente decisiones estratégicas y consumo de vueltas.

5.2.2. Función de pérdida

La función de pérdida total se define como:

$$\mathcal{L}_{total} = \mathcal{L}_{clasificación} + \alpha \cdot \mathcal{L}_{regresión}$$

donde el coeficiente α controla la contribución relativa de la tarea de regresión frente a la clasificación. Este parámetro se ajusta para priorizar la precisión estratégica en la selección del compuesto sin descuidar la coherencia temporal asociada a la duración de los stints.

5.2.3. Características del dataset y su impacto en el modelo

El conjunto de datos presenta varias propiedades que condicionan directamente la elección del enfoque de modelado.

- Naturaleza secuencial

Cada piloto en cada carrera genera una secuencia de stints de longitud variable, lo que requiere técnicas de padding dinámico y estructuras como pack_padded_sequence para un procesamiento eficiente. Esta organización encaja naturalmente con arquitecturas recurrentes como LSTM.

- Desbalanceo severo de clases

Como se evidenció en los análisis de distribución, los compuestos de lluvia (WET e INTERMEDIATE) aparecen con baja frecuencia. Esta característica intrínseca del dato conlleva el riesgo de que el modelo converja hacia soluciones triviales (prediciendo siempre seco) para maximizar la precisión global. Este condicionante estructural es el que motiva la estrategia de ponderación manual detallada en la sección anterior, indispensable para forzar al modelo a aprender patrones en escenarios minoritarios y garantizar su robustez en condiciones climáticas adversas.

5.2.4. Rendimiento esperado y métricas empleadas

Dada la naturaleza altamente estocástica de las estrategias de carrera en Fórmula 1, donde intervienen factores externos como clima, incidentes en pista y decisiones tácticas en tiempo real, no se espera que el modelo alcance precisiones propias de problemas deterministas clásicos. La predicción de estrategias constituye un problema secuencial complejo con múltiples soluciones viables para una misma carrera.

En este contexto, el objetivo principal no es la reproducción exacta de cada estrategia individual, sino la captura de patrones estratégicos dominantes y transiciones típicas entre compuestos. Por ello, métricas como la precisión en la predicción del siguiente stint (*next-step accuracy*) y la coherencia parcial de secuencias (*prefix accuracy*) resultan más representativas del rendimiento real del sistema.

Asimismo, se evalúa la precisión de secuencias completas y se analizan matrices de confusión para identificar sesgos entre compuestos, permitiendo valorar simultáneamente la precisión local, la coherencia temporal y el realismo estratégico.

Se espera que el modelo LSTM Multitask, al incorporar dependencias temporales y contexto histórico, logre precisiones moderadas pero consistentes en

la predicción del siguiente compuesto. La incorporación de ponderación de clases y modelado conjunto de duración de stints busca mejorar especialmente el rendimiento en situaciones menos frecuentes pero estratégicamente críticas.

En conjunto, la elección de un modelo LSTM multitarea se justifica por la naturaleza secuencial del problema, la presencia de dependencias temporales de largo alcance, la combinación de tareas de clasificación y regresión, la complejidad no lineal de las decisiones estratégicas y el desbalanceo estructural del dataset.

La arquitectura propuesta se alinea directamente con la lógica real de toma de decisiones en Fórmula 1, los objetivos predictivos del trabajo y las características estadísticas de los datos disponibles, constituyendo una solución metodológicamente sólida para el análisis y predicción de estrategias de neumáticos.

5.3. Preparación de Datos para el Modelo

El preprocesamiento del conjunto de datos se diseñó con el objetivo de transformar los registros originales de carrera en secuencias temporales adecuadas para su procesamiento mediante redes neuronales recurrentes. Dado que las decisiones estratégicas en Fórmula 1 dependen de la evolución histórica de cada carrera, los datos se organizaron a nivel de piloto y evento, generando secuencias de stints ordenadas cronológicamente.

Cada secuencia representa el desarrollo completo de una estrategia individual, permitiendo al modelo capturar dependencias temporales entre decisiones consecutivas.

5.3.1. Codificación de variables de entrada

Las variables se estructuraron combinando información numérica, categórica y contextual:

- Las variables numéricas continuas, como la duración del stint, el número de vueltas restantes y el orden del stint, fueron normalizadas para facilitar la estabilidad del entrenamiento.
- La variable categórica correspondiente al compuesto de neumático se transformó mediante codificación one-hot, permitiendo al modelo diferenciar explícitamente entre los distintos tipos de neumáticos.
- Se incorporaron variables binarias de contexto estratégico, incluyendo la presencia de lluvia, periodos de safety car y un indicador de último stint, con el fin de representar eventos externos relevantes en la toma de decisiones.

Adicionalmente, se incluyó información acumulativa sobre el historial de compuestos utilizados, permitiendo al modelo inferir restricciones estratégicas derivadas del uso previo de neumáticos.

5.3.2. Construcción de secuencias y padding dinámico

Dado que las carreras presentan un número variable de paradas en boxes, las secuencias generadas difieren en longitud. Para permitir el entrenamiento por lotes, se aplicó padding dinámico mediante la función pad_sequence, rellenando las secuencias cortas hasta la longitud máxima del lote correspondiente.

Para optimizar el procesamiento recurrente, se empleó la estructura pack_padded_sequence, evitando que las posiciones de padding influyeran en el aprendizaje del modelo.

5.3.3. Generación de variables objetivo multitarea

Para cada paso temporal de la secuencia se definieron dos variables objetivo:

- Una variable categórica correspondiente al compuesto de neumático del siguiente stint, destinada a la tarea de clasificación.
- Una variable continua correspondiente a la duración del siguiente stint en número de vueltas, utilizada en la tarea de regresión.

Este planteamiento permite modelar explícitamente la transición entre decisiones estratégicas consecutivas, alineándose con la dinámica real de la planificación de carrera.

5.3.4. División del conjunto de datos

El conjunto de datos se dividió en subconjuntos de entrenamiento y prueba, respetando la estructura secuencial por piloto y carrera con el fin de evitar fugas de información temporal entre ambas particiones. Esta estrategia garantiza que las secuencias utilizadas para evaluación no hayan sido observadas durante el proceso de aprendizaje.

Durante el entrenamiento se monitorizó la evolución de la función de pérdida para asegurar la convergencia del modelo, mientras que el rendimiento final se evaluó sobre el conjunto de prueba independiente.

La ausencia de un conjunto de validación independiente responde a la necesidad de preservar el mayor número posible de secuencias para entrenamiento, especialmente en eventos minoritarios de alto impacto estratégico. Dado que el modelo se evalúa sobre un conjunto de prueba separado y se monitoriza la convergencia de la función de pérdida durante el entrenamiento, se

considera que este enfoque proporciona una estimación fiable del rendimiento sin comprometer la capacidad de aprendizaje.

5.4. Estrategia de Entrenamiento y Optimización

El objetivo de esta fase fue evaluar la capacidad de aprendizaje de arquitecturas recurrentes aplicadas a secuencias de estrategia de neumáticos en Fórmula 1, establecer una línea base de rendimiento y analizar hasta qué punto los modelos son capaces de reproducir patrones estratégicos coherentes con la dinámica real de carrera. Esta etapa permitió identificar limitaciones metodológicas de aproximaciones iniciales y proporcionar una base sólida para optimizaciones posteriores.

5.4.1. Entrenamiento Inicial (Baseline)

Como primer enfoque, se empleó una arquitectura LSTM simple con una única salida de clasificación del compuesto de neumático (tabla 3). Esta configuración sirvió como modelo base para comprender el comportamiento de redes recurrentes básicas en el problema de predicción secuencial de estrategias.

Parámetro	**Valor**
Dimensión de entrada	17
Unidades ocultas LSTM	64
Tamaño de batch	32
Epochs	25
Learning rate	0.001
Optimizador	Adam
Función de pérdida	Cross-Entropy

Tabla 3. Hiperparámetros del modelo LSTM base.

El modelo se entrenó utilizando secuencias de stints por piloto y carrera. Para cada muestra, la red recibe el estado acumulado de la carrera hasta un determinado stint y predice el compuesto del siguiente stint (tabla 4), preservando así la dependencia temporal entre decisiones estratégicas consecutivas.

Las variables numéricas continuas fueron estandarizadas empleando estadísticas calculadas exclusivamente sobre el conjunto de entrenamiento. Este preprocesamiento permitió homogeneizar las escalas de entrada, estabilizar los gradientes y favorecer una convergencia más eficiente, asegurando que el modelo respondiera de manera consistente ante variaciones en duración de stints, contexto de carrera y condiciones de pista.

Variable	Tipo original	Codificación	Dimensión	Preprocesamiento
stint_number	Numérica discreta	Valor continuo	1	Sin transformación
stint_length	Numérica continua	Valor continuo	1	Sin transformación
laps_remaining	Numérica continua	Valor continuo	1	Sin transformación
SC	Binaria	0/1	1	Conversión [0,1]
VSC	Binaria	0/1	1	Conversión [0,1]
Rain	Binaria	0/1	1	Conversión [0,1]
is_final_stint	Binaria	0/1	1	Conversión [0,1]
current_tyre	Categórica	One-hot	5	Codificación one-hot
tyres_used_so_far	Categórica multivalor	Multi-hot	5	Codificación acumulativa

Tabla 4. Variables de entrada y tratamiento previo del modelo LSTM.

Durante el entrenamiento se utilizó Teacher Forcing completo, de modo que el modelo siempre recibe los valores reales de los stints anteriores. Aunque la estructura simula un comportamiento autorregresivo, el sistema no aprende a condicionarse sobre sus propias predicciones durante el aprendizaje; la autorregresión real se produce únicamente durante la inferencia, cuando se generan secuencias completas utilizando las salidas del modelo como entradas sucesivas.

Esta configuración permitió establecer una línea base de rendimiento del modelado LSTM simple además de poder identificar limitaciones de modelos secuenciales básicos, como la acumulación de errores y la dependencia de valores reales previos.

5.4.1.1. División de datos de entrenamiento

Los datos se dividieron en conjunto de entrenamiento (80%) y conjunto de prueba (20%), preservando la integridad de las secuencias por piloto y carrera. Todas las muestras correspondientes a una misma combinación piloto–carrera se asignaron exclusivamente a uno de los conjuntos, evitando fugas de información entre entrenamiento y test (tabla 5).

Esta estrategia garantiza que el modelo aprenda patrones secuenciales completos y permite evaluar de manera realista su capacidad de generalización a carreras no vistas.

Conjunto	Carreras	Stints
Entrenamiento	52	1758
Test	14	504

Tabla 5. Distribución del conjunto de datos.

5.4.1.2. Fase de entrenamiento

El entrenamiento se realizó iterando sobre todas las secuencias del conjunto de entrenamiento agrupadas por piloto y carrera. En cada época, se procesaron los lotes (batches) generados por el DataLoader, calculando la función de pérdida y actualizando los pesos de la red mediante retropropagación.

Los elementos principales del proceso fueron:

- Función de pérdida: CrossEntropyLoss para clasificación multiclase del compuesto de neumático, incluyendo un token de finalización de secuencia.
- Optimizador: Adam con tasa de aprendizaje de 0.001, permitiendo una convergencia estable.
- Actualización por batch: predicción del siguiente stint, cálculo de pérdida, retropropagación y actualización de pesos.
- Teacher Forcing completo: uso de valores reales en cada paso temporal.
- Estandarización de variables numéricas: aplicada previamente para estabilidad del aprendizaje.

El rendimiento del modelo se evaluó mediante métricas orientadas a problemas de predicción secuencial y clasificación multiclase. En primer lugar, se emplearon métricas específicas de secuencia:

- Prefix Accuracy (k): métrica secuencial que cuantifica la fracción de muestras para las cuales la subsecuencia predicha de longitud *k* coincide exactamente con la subsecuencia real, permitiendo evaluar el desempeño del modelo en las decisiones tempranas de la estrategia de neumáticos.
- Exact Sequence Accuracy: métrica estricta que mide la coincidencia exacta entre la secuencia predicha y la secuencia real en toda su longitud, reflejando la capacidad del modelo para simular estrategias completas de carrera.

Además, se utilizó la métrica Next-step Classification Accuracy, que mide la proporción de aciertos en la predicción del compuesto del siguiente stint, evaluando la capacidad del modelo para capturar patrones locales de decisión a lo largo de la secuencia.

Para analizar el comportamiento del modelo por tipo de neumático, se recurrió a métricas clásicas de clasificación multiclase tales como precisión, recall y F1-score.

Dado el fuerte desbalance entre compuestos secos y de lluvia presente en los datos, se reportaron además promedios micro, macro y ponderados, weighted, permitiendo evaluar tanto el rendimiento global como el comportamiento en clases minoritarias.

Finalmente, se generó una matriz de confusión, que resume las predicciones correctas e incorrectas por clase, facilitando la identificación de patrones de confusión entre compuestos y evidenciando el impacto del desbalance de datos sobre el desempeño del modelo.

Este conjunto de métricas permite medir tanto la capacidad táctica local como el comportamiento en simulaciones completas, estableciendo una referencia objetiva para comparaciones posteriores.

5.4.1.3. Organización temporal de los datos de entrenamiento

Se analizó el impacto del orden de presentación de las secuencias mediante dos enfoques:

- Orden temporal global: secuencias organizadas por identificador de carrera.
- Muestreo aleatorio: selección aleatoria de secuencias completas, manteniendo su estructura interna.

Los resultados muestran que, aunque el modelo aprende correctamente patrones estratégicos locales, su capacidad para reproducir secuencias completas es limitada, como reflejan los bajos valores de Exact Sequence Accuracy (tabla 6). La Prefix Accuracy alcanza hasta un 75% en los dos primeros stints bajo muestreo aleatorio, reduciéndose al extender la secuencia, lo que evidencia la acumulación de errores típica de modelos autorregresivos entrenados con Teacher Forcing.

Asimismo, el entrenamiento con secuencias aleatorias presenta un rendimiento superior al orden temporal fijo, al exponer al modelo a una mayor diversidad de contextos estratégicos en cada época. Dado que la dependencia temporal relevante se encuentra dentro de cada piloto–carrera y no entre secuencias distintas, este enfoque favorece una optimización más estable y se adoptó como estándar para fases posteriores.

Métrica	Aleatorio	Secuencia ordenada
Exact sequence accuracy	0.017	0.025
Prefix accuracy (2 stints)	0.754	0.640
Prefix accuracy (3 stints)	0.385	0.204

Tabla 6. Métricas del modelo base.

En conjunto, esta fase permitió establecer una línea base clara de rendimiento, identificar limitaciones estructurales del enfoque secuencial básico y seleccionar configuraciones de entrenamiento adecuadas para desarrollos posteriores.

5.4.2. Optimización del Modelo

La fase de optimización del modelo tuvo como objetivo mejorar la capacidad predictiva de la red neuronal secuencial y corregir las limitaciones observadas en el modelo base, particularmente la acumulación de errores durante simulaciones autorregresivas completas y el sesgo hacia los compuestos mayoritarios. Dado el carácter altamente no lineal del problema de estrategia en Fórmula 1 y la dependencia temporal entre decisiones consecutivas, esta etapa se centró en el ajuste de hiperparámetros críticos, en la estabilización del aprendizaje secuencial y en la mejora de la capacidad de generalización del sistema.

5.4.2.1. Ajuste de Hiperparámetros

A partir del modelo LSTM inicial se identificaron como hiperparámetros con mayor impacto potencial en el rendimiento: la dimensión del estado oculto de la red recurrente, la tasa de aprendizaje del optimizador Adam, el coeficiente de ponderación de la tarea de regresión dentro del esquema multitarea y el número de épocas de entrenamiento. Estos parámetros influyen directamente tanto en la capacidad de representación de dependencias temporales complejas como en la estabilidad del proceso de optimización.

Debido al elevado coste computacional del entrenamiento de modelos secuenciales y a la naturaleza continua de varios hiperparámetros, se adoptó una estrategia de búsqueda aleatoria acotada (Random Search), explorando progresivamente combinaciones relevantes del espacio de parámetros. Este enfoque resulta más eficiente que la búsqueda exhaustiva en espacios de alta dimensionalidad, tal como demuestran Bergstra y Bengio (2012), especialmente en modelos de aprendizaje profundo donde solo un subconjunto reducido de hiperparámetros tiene impacto dominante en el rendimiento.

Como métrica principal de optimización se utilizó Next-step Classification Accuracy sobre el conjunto de prueba, complementada por las métricas de Prefix

Accuracy. Estas métricas reflejan de forma más estable la capacidad del modelo para aprender transiciones estratégicas realistas que la coincidencia estricta de secuencias completas, altamente sensible a errores acumulativos.

Los rangos explorados y la configuración inicial seleccionada se resumen en la tabla 7.

Hiperparámetro	Rango Explorado	Valor inicial
Hidden size LSTM	{64, 96, 128, 160}	64
Batch size	{16, 32, 64}	32
Epochs	{20, 30, 40}	25
Learning rate	$\{1\cdot10^{-3}, 5\cdot10^{-4}, 1\cdot10^{-4}\}$	$1\cdot10^{-3}$

Tabla 7. Configuración inicial de los hiperparámetros de LSTM simple.

El incremento de la dimensión del estado oculto permitió capturar relaciones temporales más complejas entre stints consecutivos, mientras que la reducción moderada de la tasa de aprendizaje favoreció una convergencia más estable en el contexto multitarea.

5.4.2.2. Regularización y Generalización

En problemas secuenciales autorregresivos, las fuentes de sobreajuste difieren de las presentes en tareas de clasificación estática. La dependencia excesiva de valores reales previos durante el entrenamiento, Teacher Forcing, y la propagación de errores en inferencia libre constituyen los principales riesgos de degradación del rendimiento.

En lugar de aplicar técnicas genéricas como Dropout o penalizaciones L1/L2, se priorizó un control implícito de la generalización basado en la estructura del problema y en el seguimiento sistemático del comportamiento del modelo. Para ello se implementaron varias estrategias complementarias.

En primer lugar, la partición de datos se realizó por carreras completas, garantizando que ninguna secuencia parcial de una misma carrera apareciera simultáneamente en entrenamiento y prueba, evitando así fugas de información temporal.

A continuación, se monitorizaron conjuntamente las pérdidas de clasificación y regresión, así como las métricas de precisión en ambos conjuntos, permitiendo detectar posibles divergencias indicativas de sobreajuste.

Scheduled Sampling y ajuste del hiperparámetro de Teacher Forcing

Una de las optimizaciones metodológicas clave fue la incorporación de la técnica de Scheduled Sampling. En este enfoque, la probabilidad de utilizar las salidas reales como entradas para el siguiente paso de la secuencia se reduce linealmente desde 1.0 hasta 0.3 a lo largo de las épocas de entrenamiento, forzando

al modelo a condicionarse progresivamente sobre sus propias predicciones. Este mecanismo reduce la discrepancia entre el entorno de entrenamiento, dominado por Teacher Forcing completo, y el entorno de inferencia autorregresiva real, mitigando la acumulación de errores en simulaciones completas de carrera y mejorando la estabilidad secuencial del sistema.

Los resultados obtenidos con el modelo base evidenciaron una fuerte degradación del rendimiento al generar secuencias completas, consecuencia directa del uso exclusivo de valores reales como entrada durante el entrenamiento, lo que impide al modelo aprender a corregir errores acumulativos en inferencia. Para abordar esta limitación, se exploraron valores del parámetro final de Teacher Forcing dentro de un rango moderado (0.2–0.4), comúnmente empleado en la literatura de modelado secuencial para equilibrar estabilidad de aprendizaje y autonomía predictiva. En concreto, se evaluaron empíricamente los valores 0.2, 0.3 y 0.4.

Dado que la aplicación de Scheduled Sampling expone al modelo a sus propias predicciones durante el entrenamiento, la métrica Next-step Accuracy pierde representatividad como criterio principal de optimización, al no reflejar de forma fiel la capacidad del sistema para generar secuencias coherentes en régimen autorregresivo. Por este motivo, se priorizaron métricas secuenciales como Prefix Accuracy y Exact Sequence Accuracy, que capturan de manera más realista la coherencia temporal y la calidad estratégica de las secuencias generadas.

Los resultados muestran una mejora sustancial respecto al modelo base, especialmente en la reproducción de secuencias completas de carrera (tabla 8). En particular, el valor Teacher_end = 0.3 alcanzó el mejor desempeño global, maximizando tanto Exact Sequence Accuracy (0.341) como Prefix Accuracy a tres stints (0.443), sin comprometer la coherencia inicial de las predicciones. Esta configuración fue seleccionada como óptima para los experimentos posteriores.

Modelo	**Teacher_end**	**Prefix Accuracy 2 stints**	**Prefix Accuracy 3 stints**	**Exact Sequence Accuracy**
Baseline	1	0.754	0.385	0.017
SS	0.2	0.732	0.433	0.335
SS	0.3	0.741	0.443	0.341
SS	0.4	0.754	0.421	0.330

Tabla 8. Comparativa de desempeño entre el modelo base y con Sheduled Sample (SS).

Aprendizaje Multitarea como regularización estructural

El modelo final predice simultáneamente el neumático del siguiente stint (clasificación) y la duración del stint (regresión).

Este enfoque multitarea actúa como regularización estructural, debido a que fuerza al modelo a aprender representaciones latentes que expliquen simultáneamente decisiones estratégicas y consumo de vueltas.

Empíricamente se observó una mayor estabilidad del entrenamiento, mejor coherencia temporal de secuencias generadas y reducción de predicciones incoherentes (stints imposibles).

Manejo del Desbalance de Clases

El conjunto de datos presenta un fuerte desbalance entre compuestos de seco (principalmente HARD y MEDIUM) y compuestos de lluvia, que aparecen con mucha menor frecuencia. Este sesgo puede inducir al modelo a privilegiar sistemáticamente las clases mayoritarias, degradando su capacidad de generalización en escenarios de carreras menos frecuentes pero estratégicamente críticos.

Para corregir este efecto, se incorporaron pesos de clase en la función de pérdida de clasificación, CrossEntropy Loss, asignando mayor penalización a las clases minoritarias. Los pesos fueron definidos de forma suavizada a partir de las proporciones observadas en el conjunto de entrenamiento, evitando inestabilidades numéricas y colapsos hacia clases dominantes (tabla 9).

Compuesto	Peso aplicado en CrossEntropy
SOFT	3.5
MEDIUM	1.0
HARD	1.1
INTERMEDIATE	4.5
WET	6.0
<END>	1.0

Tabla 9. Pesos de clase utilizados en la función de pérdida de clasificación para corregir el desbalance del conjunto de datos.

Este mecanismo mejora la sensibilidad del modelo ante situaciones de lluvia y contribuye a una representación estratégica más equilibrada del espacio de decisiones.

Restricciones de Dominio y Simulación Dinámica

Durante la inferencia se incorporó conocimiento físico del dominio mediante una restricción explícita del espacio de predicción: los compuestos INTERMEDIATE y WET fueron prohibidos en ausencia de lluvia. Esta técnica, denominada Rain Masking, evita soluciones estratégicamente inviables y mejora la coherencia realista de las secuencias generadas.

A su vez, el estado de carrera se actualizó dinámicamente tras cada predicción, modificando el número de vueltas restantes y las variables contextuales. De este

modo, cada decisión estratégica depende del progreso real de la simulación, aproximando el comportamiento del modelo a una simulación estratégica cerrada y realista.

5.5. Evaluación de la Generalización

El sobreajuste se evaluó mediante la comparación sistemática de las métricas entre los conjuntos de entrenamiento y prueba, así como a través del análisis de la evolución de las funciones de pérdida multitarea, clasificación y regresión, a lo largo de las épocas (figuras 20 y 21). Se observó que la brecha (gap) de rendimiento entre ambos conjuntos se mantuvo constante en un rango aproximado del 10-11%, sin mostrar signos de ensanchamiento progresivo.

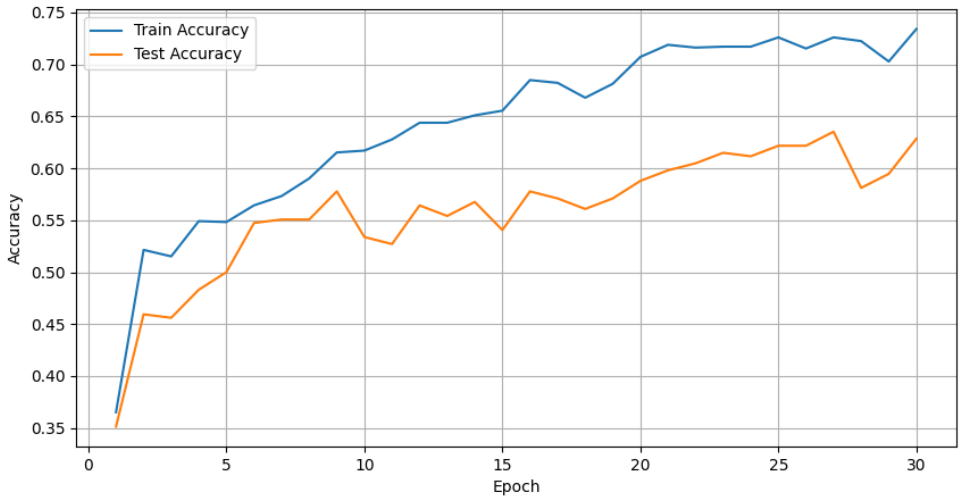

Figura 20. Evolución de la métrica Next-step Accuracy en el conjunto de datos de entrenamiento y de test a lo largo de 30 épocas.

Esta estabilidad indica que el modelo está aprendiendo patrones estratégicos generales en lugar de limitarse a memorizar los datos de entrenamiento. Dicha diferencia del 10% se interpreta como el ruido estructural inherente a la Fórmula 1, la incertidumbre estocástica propia de la competición, y no como una deficiencia de la arquitectura. En consecuencia, la convergencia estable valida una adecuada capacidad de generalización, transformando el modelo base en un sistema robusto y representativo de las dinámicas reales.

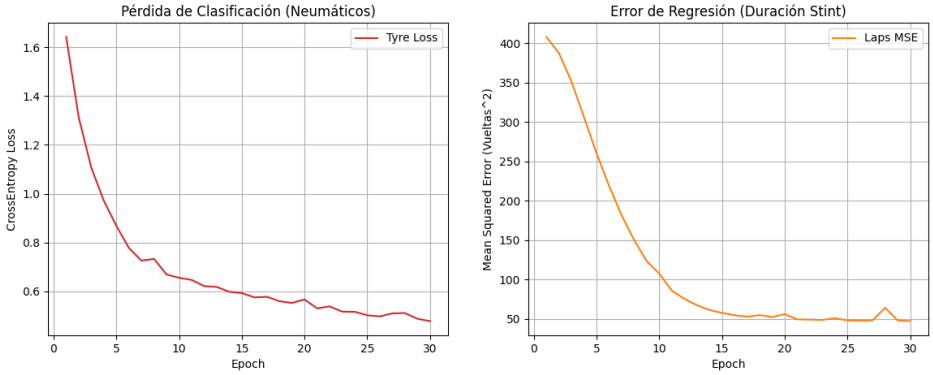

Figura 21. Evolución de las funciones de pérdida de clasificación y regresión.

6. Resultados y Evaluación del Modelo

Una vez descrita la arquitectura del modelo, el proceso de preprocesamiento de datos y las optimizaciones metodológicas implementadas, incluyendo el enfoque multitarea, la ponderación de clases en la función de pérdida y la incorporación de Scheduled Sampling, en este capítulo se presentan los resultados experimentales obtenidos sobre el conjunto de test. El objetivo es analizar de forma rigurosa el impacto de estas mejoras en la capacidad del sistema para aprender estrategias de neumáticos coherentes y generalizables en condiciones de carrera no vistas durante el entrenamiento.

De acuerdo con los objetivos definidos en capítulos anteriores, la evaluación se centra en tres dimensiones fundamentales: la precisión en la predicción secuencial de decisiones estratégicas, la corrección del sesgo hacia clases mayoritarias de neumáticos y la robustez del modelo frente a eventos minoritarios como condiciones de lluvia. Para ello, se emplean métricas que permiten analizar tanto el rendimiento inmediato de cada predicción como la coherencia global de las secuencias completas generadas de forma autorregresiva.

En particular, se comparan los resultados del Modelo Inicial, LSTM simple, con los del Modelo Final, LSTM multitarea optimizado, con el fin de cuantificar el efecto de cada mejora metodológica introducida. La evaluación se realiza exclusivamente sobre carreras no utilizadas durante el entrenamiento, garantizando así que las métricas reflejan la capacidad real de generalización del sistema.

El análisis de resultados se estructura en cuatro bloques principales. En primer lugar, se estudia el rendimiento secuencial global del modelo mediante métricas como Next-step Accuracy, Prefix Accuracy y Exact Sequence Accuracy. Posteriormente, se examina el desempeño por tipo de neumático a través de informes de clasificación detallados. A continuación, se analiza la matriz de

confusión para caracterizar los patrones de decisión aprendidos. Finalmente se identifican los principales errores sistemáticos y limitaciones de la arquitectura propuesta.

6.2. Análisis de Métricas Globales

En primer lugar, se contrastan las métricas de rendimiento global para cuantificar la capacidad del modelo tanto en decisiones inmediatas como en la simulación de secuencias a largo plazo.

Métrica	Modelo inicial	Modelo final	Variación
Next-step Accuracy	77.58%	62.84%	-14.74%
Prefix Accuracy (2 stints)	75.42%	69.94%	-5.48%
Exact Sequence Accuracy	1.12%	11.56%	+1.03%

Tabla 10. Comparativa de métricas globales de rendimiento.

Aunque se registra un descenso en la métrica Next-step Accuracy respecto al modelo inicial, baseline, este fenómeno no debe interpretarse como una degradación del aprendizaje, sino como una redistribución del riesgo estratégico. El modelo inicial maximizaba su métrica apostando sistemáticamente a la clase mayoritaria (pista seca/HARD), mientras que el modelo final sacrifica aciertos triviales para arriesgarse a predecir eventos complejos.

El beneficio de esta aproximación se refleja en Exact Sequence Accuracy, que se ha multiplicado por diez (1.12% vs 11.56%). Esto valida la eficacia del Scheduled Sampling y la arquitectura multitarea para mitigar la acumulación de errores, dotando al sistema de una coherencia global necesaria para simulaciones de carrera completas.

6.2. Detalle de Rendimiento por Clase

Para comprender cómo la ponderación de clases ha alterado el comportamiento del modelo, se presentan a continuación los informes de clasificación detallados para ambos modelos. Las tablas 11 y 12 desglosan la Precision, Recall y F1-Score para cada compuesto, permitiendo un análisis conjunto del desempeño en clases desbalanceadas.

6.2.1. Rendimiento del Modelo Inicial

El modelo base exhibe un comportamiento conservador, sesgado hacia las clases mayoritarias.

Clase (Neumático)	Precision	Recall	F1-Score	Support
SOFT	0.44	0.31	0.36	26
MEDIUM	0.57	0.50	0.53	92
HARD	0.74	0.81	0.77	195
INTERMEDIATE	0.00	0.00	0.00	12
WET	0.00	0.00	0.00	0
Accuracy Global			0.65	352

Tabla 11. Informe de Clasificación – Modelo Inicial.

Como se observa en la Tabla 4.2, el modelo inicial es tácticamente ciego a la lluvia. Con un Recall de 0.00 en la clase INTERMEDIAT*E*, el sistema ignora sistemáticamente las condiciones climáticas adversas, manteniendo una estrategia de seco que resultaría inviable y peligrosa en pista. Maximiza su Accuracy global a costa de fallar en los momentos críticos.

6.2.2. Rendimiento del Modelo Final

El modelo final, tras aplicar la reponderación de clases en la función de pérdida, muestra un perfil de decisión radicalmente distinto, priorizando la detección de eventos minoritarios.

Clase (Neumático)	Precision	Recall	F1-Score	Interpretación
SOFT	0.44	0.31	0.36	Mantiene capacidad de ataque
MEDIUM	0.55	0.28	0.37	Degradación por confusión con HARD
HARD	0.72	0.81	0.76	Mantiene robustez en clase dominante
INTERMEDIATE	0.42	0.62	0.50	Reacción efectiva a la lluvia
Accuracy Global				

Tabla 12. Informe de Clasificación – Modelo Final.

Los resultados de la tabla 12 evidencian la superación del sesgo mayoritario:

- Detección Robusta de Lluvia: El Recall de la clase INTERMEDIATE asciende drásticamente del 0.00 al 0.62. El modelo ha aprendido las reglas de activación meteorológicas. El F1-Score de 0.50 refleja un equilibrio competente entre detectar la lluvia y no generar falsas alarmas excesivas.
- Sensibilidad vs. Precisión: La precisión en intermedios de 0.42 indica la existencia de falsos positivos. Estratégicamente, esto actúa como un sistema de alerta temprana: el modelo prefiere advertir de una posible lluvia (arriesgando una parada innecesaria) antes que ignorar una lluvia real (que conllevaría un accidente).
- Sacrificio en la Clase Medium: Se observa una caída notable en el Recall de MEDIUM del 0.50 al 0.28, lo que reduce su F1-Score a 0.37. Este es el coste de oportunidad de la ponderación: al obligar al modelo a mirar la lluvia y los blandos, la distinción sutil entre MEDIUM y HARD se difumina.

6.3. Análisis de la Matriz de Confusión

La mejora cualitativa se visualiza en la dispersión de la diagonal de la matriz de confusión.

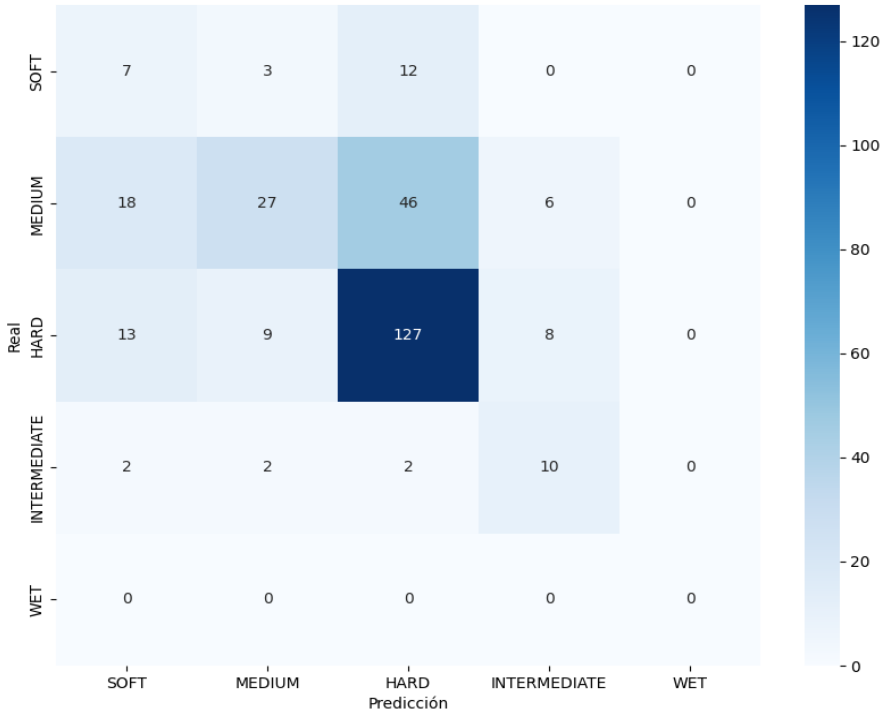

Figura 6. Matriz de confusión del Modelo Final.

A diferencia del modelo inicial, que concentraba todas las predicciones en una columna vertical (prediciendo siempre HARD/MEDIUM), el modelo final

distribuye sus decisiones. Se aprecia una mayor dispersión en la diagonal correspondiente a las clases minoritarias, lo que confirma una mejor cobertura del espacio de decisiones estratégicas posibles.

6.4. Análisis de Errores y Limitaciones

El examen detallado de las predicciones incorrectas permite identificar tres patrones de error sistemáticos que definen el límite actual de la arquitectura propuesta:

6.4.1. Confusión MEDIUM vs HARD

El principal efecto colateral de la ponderación de clases ha sido la degradación en la identificación del neumático MEDIUM (Recall 28%).

- Causa: Al penalizar fuertemente los errores en clases extremas (SOFT, INTERMEDIATE) y tener pesos similares para MEDIUM y HARD, el modelo encuentra dificultades para discriminar entre ambos en stints de longitud intermedia. Dado que la telemetría agregada (vueltas restantes, posición) puede ser muy similar para ambos compuestos en la fase media de carrera, el modelo tiende a converger hacia HARD por su mayor prevalencia histórica.

6.4.2. Degradación Temporal

Se observa una caída del rendimiento predictivo correlacionada con la longitud de la secuencia simulada. Prefix Accuracy desciende del ~70% (2 stints) al ~30% (3 stints). A pesar del uso de Scheduled Sampling, el error en modelos autorregresivos es inherentemente acumulativo. En la Fórmula 1, las decisiones del tercer o cuarto stint dependen de variables exógenas no modeladas (tráfico, incidentes, evolución de la pista) que introducen un ruido estructural difícil de anticipar desde el inicio de la carrera.

6.4.3. Falsos Positivos de Lluvia

Como indica Precisión del 42% en la clase INTERMEDIATE, el modelo predice lluvia en ocasiones donde no ocurre. Este comportamiento conservador es inducido por los altos pesos asignados a la clase WET en la función de pérdida. Estratégicamente, se considera un fallo seguro, ya que alerta al ingeniero sobre la posibilidad de condiciones adversas.

6.5. Propuestas de Mejora

Basado en la caracterización de errores realizada, se proponen las siguientes líneas de trabajo futuro fundamentadas en los patrones de error observados:

- Enriquecimiento del Dataset (Telemetría Granular): Para resolver la confusión MEDIUM/HARD, se propone incorporar la pendiente de degradación de tiempos por vuelta. Esta variable física permitiría distinguir entre un neumático medio (degradación pronunciada) y uno duro (degradación estable) observando la pérdida de rendimiento vuelta a vuelta, más allá de la simple duración del stint.
- Mecanismos de Atención (Transformers): Para mitigar el olvido en secuencias largas, la sustitución de la celda LSTM por mecanismos de Self-Attention permitiría al modelo ponderar mejor el contexto global de la carrera (ej. posición en parrilla o temperatura inicial) al tomar decisiones en los últimos stints, reduciendo la dependencia exclusiva del estado oculto inmediato.

En conclusión, los resultados experimentales validan que la incorporación de restricciones de dominio y técnicas de aprendizaje sensible al coste transforma un modelo estadístico secuencial básico en una herramienta de soporte a la decisión capaz de capturar la dinámica compleja y no lineal de la estrategia de neumáticos en Fórmula 1.

7. Interpretabilidad del Modelo

En el ámbito del aprendizaje profundo, Deep Learning, y específicamente en modelos secuenciales como las redes LSTM, existe el desafío inherente de la caja negra: la dificultad para entender los mecanismos internos que llevan al modelo a tomar una decisión específica. Este capítulo tiene como objetivo arrojar luz sobre el proceso de toma de decisiones del modelo propuesto, identificando qué variables tienen mayor peso en la predicción de estrategias de neumáticos y evaluando si el modelo presenta sesgos que puedan afectar la equidad o seguridad de las predicciones.

7.1. Explicación del Modelo

Para analizar la importancia de las características, feature importance, se ha seleccionado la técnica SHAP (SHapley Additive exPlanations), un enfoque basado en la teoría de juegos que asigna a cada característica un valor de importancia para una predicción particular.

Debido a la arquitectura recurrente (LSTM) y al uso de secuencias de longitud variable, Packed Sequences, las herramientas estándar de cálculo de gradientes de SHAP, DeepExplainer, presentan incompatibilidades técnicas conocidas con la versión actual de PyTorch. Para solventar esto y garantizar una interpretación robusta, se ha optado por utilizar SHAP KernelExplainer, un método agnóstico al modelo. Se ha analizado la importancia de las características en el último paso

temporal de la secuencia de decisión. Esta aproximación es válida en este contexto específico porque nuestras variables de entrada (como tyres_used_so_far y laps_remaining) ya codifican explícitamente la información histórica relevante, permitiendo interpretar la decisión del modelo basándonos en el estado actual de la carrera.

7.1.1. Análisis de Importancia de Características

La figura 22 presenta el impacto medio absoluto de las principales variables en la salida del modelo. Este gráfico permite validar si el modelo está utilizando una lógica alineada con el conocimiento experto de la Fórmula 1.

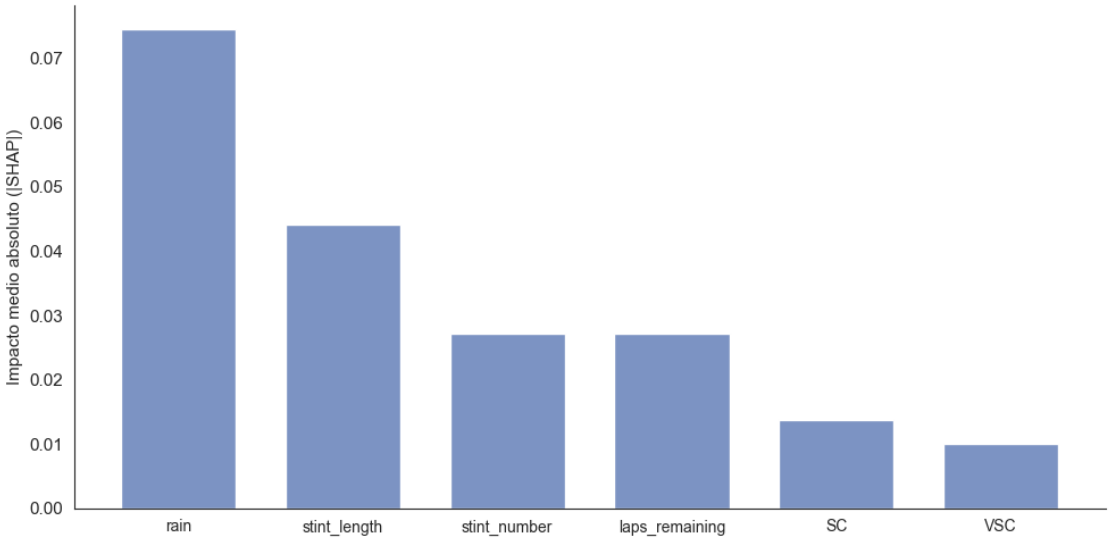

Figura 22. Importancia global de las características basadas en valores SHAP (KernelExplainer)

Del análisis de la figura 22 se extraen las siguientes conclusiones sobre el comportamiento del modelo:

- Dominio de las Condiciones Ambientales (rain): La variable con mayor impacto en las predicciones es, con diferencia, la presencia de lluvia. Esto es coherente con la realidad de la competición: un cambio en las condiciones climáticas obliga a un cambio inmediato y determinista de estrategia (hacia neumáticos INTERMEDIATE o de WET), anulando cualquier planificación previa. Que el modelo identifique rain como el factor preponderante indica que ha aprendido correctamente a priorizar la seguridad y la adherencia sobre el desgaste.
- Gestión del Desgaste y Carrera (stint_length y stint_number): Las siguientes variables en importancia son la longitud del stint actual y el número de stint. Esto sugiere que el modelo basa gran parte de su decisión en la degradación acumulada del neumático actual. El modelo entiende que cuantos más

giros acumula un neumático (stint_length), mayor es la probabilidad de una parada en boxes.

- Contexto de Carrera (laps_remaining): Las vueltas restantes actúan como un factor de contrapeso. El modelo utiliza esta información para decidir si merece la pena realizar una parada adicional o si es preferible conservar la posición en pista hasta el final.
- Eventos Esporádicos (SC y VSC): Resulta interesante notar que el Safety Car y el Virtual Safety Car tienen un impacto menor en comparación con el clima o el desgaste. Esto puede interpretarse como que, si bien estos eventos ofrecen oportunidades tácticas, no dictan la estrategia fundamental con la misma fuerza que la lluvia o la degradación física del compuesto.

Este desglose confirma que el modelo no se está basando en ruido estadístico, sino que ha internalizado las reglas físicas y estratégicas básicas de la Fórmula 1: el clima dicta el compuesto, y el desgaste dicta el momento de la parada.

7.2. Evaluación de Sesgos

Además de entender qué mira el modelo, es crucial evaluar cómo se comporta ante diferentes subgrupos de datos para identificar posibles sesgos que puedan derivar en predicciones injustas o inseguras.

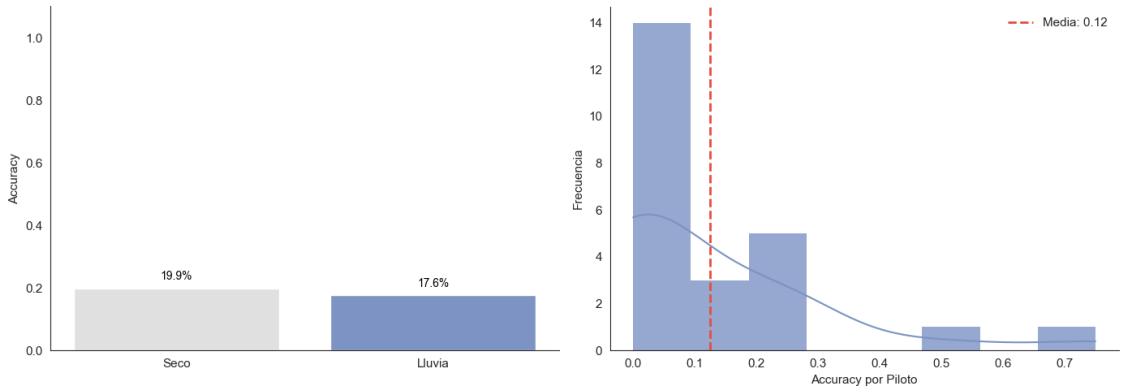

Figura 23. Evaluación de sesgos. Izquierda: Robustez Climática. Derecha: Consistencia de predicción entre diferentes pilotos.

7.2.1. Robustez Climática (Sesgo de Seguridad)

El panel izquierdo de la figura 23 evalúa el rendimiento del modelo segregado por condiciones de pista, registrando una Accuracy del 19.9% en condiciones de seco frente a un 17.6% en situaciones de lluvia.

Se observa una diferencia de rendimiento de aproximadamente 2.3 puntos porcentuales en detrimento de las condiciones de lluvia. Aunque existe un sesgo, este es moderado. La caída en rendimiento es esperable debido a dos factores: primero, el desbalance de clases inherente al dataset (hay muchas menos carreras

en lluvia para entrenar); y segundo, la naturaleza caótica de las carreras en mojado, donde las decisiones estratégicas son más subjetivas y menos basadas en datos históricos de degradación. No obstante, la cercanía entre ambas métricas sugiere que el modelo mantiene una robustez aceptable y no falla catastróficamente ante condiciones adversas.

7.2.2. Consistencia entre Pilotos (Sesgo de Equidad)

El histograma del panel derecho de la figura 23 muestra la distribución de Accuracy calculada individualmente para cada piloto en el conjunto de prueba, con una media de 0.12 y una distribución asimétrica positiva.

El análisis revela una variabilidad significativa en la capacidad del modelo para predecir las estrategias de diferentes pilotos.

- Grupo Mayoritario (Baja Predictibilidad): La gran mayoría de los pilotos se agrupan en el rango de exactitud 0.0 - 0.2. Esto indica que para la clase media de la parrilla, donde las estrategias suelen ser reactivas y dependientes del tráfico, al modelo le cuesta generalizar.
- Valores Atípicos de Alto Rendimiento: Existen pilotos (barras en 0.5 y 0.7) cuyas estrategias son predichas con una exactitud muy superior a la media. Esto sugiere un sesgo hacia equipos o pilotos con estrategias altamente estructuras y consistentes (probablemente los equipos punteros con menor interferencia de tráfico).

En conclusión, el modelo presenta un sesgo de "consistencia estratégica": funciona significativamente mejor para aquellos actores que siguen patrones lógicos y predecibles, mientras que su rendimiento decae con pilotos cuyas decisiones son más erráticas o forzadas por circunstancias de carrera externas.

8. Discusión

7.1. Evaluación del Enfoque Multitarea y el Aprendizaje Secuencial

El paso de un modelo base LSTM simple a una arquitectura multitarea LSTM Multitask optimizada representa el hallazgo central de este trabajo. Aunque el modelo inicial presentaba una métrica de Next-step Accuracy superior (77.58%), dicho rendimiento era un espejismo estadístico derivado del marcado desbalance de clases. El sistema original maximizaba sus aciertos mediante una apuesta sistemática por la clase mayoritaria (compuestos de seco), resultando en una ceguera táctica absoluta ante condiciones de lluvia, con un Recall de 0.00 para neumáticos intermedios.

Por el contrario, el modelo final, a pesar de registrar una caída en Next-step Accuracy (62.84%), demuestra una madurez estratégica superior. El incremento de diez veces en la *Exact Sequence Accuracy* del 1.12% al 11.56% valida que la combinación de Scheduled Sampling y aprendizaje multitarea ha mitigado eficazmente la acumulación de errores en simulaciones autorregresivas. El modelo ya no busca solo el acierto local, sino la coherencia de la secuencia completa, permitiendo que las decisiones tempranas condicionen de forma realista los estados futuros.

7.2. Lógica Interna e Interpretabilidad de las Decisiones

El análisis mediante SHAP KernelExplainer confirma que la red neuronal no ha operado como una "caja negra" basada en ruido, sino que ha internalizado las reglas fundamentales de la Fórmula 1. La jerarquía de importancia de variables identificada coincide con la doctrina estratégica del sector:

- Prioridad Climática: La variable rain es el factor más influyente, reflejando que el clima dicta de forma determinista el cambio hacia compuestos de lluvia para garantizar la seguridad y adherencia.
- Gestión de la Degradación: La relevancia de las variables stint_length y stint_number sugiere que el modelo interpreta correctamente el desgaste físico del neumático como el principal disparador de una parada en boxes.
- Contexto Global: Las vueltas restantes, laps_remaining, actúan como un factor de equilibrio que permite al sistema discernir si la ventaja táctica de un cambio de neumáticos compensa el tiempo perdido en el pit-lane según la fase de la carrera.

7.3. Caracterización de Errores y Limitaciones del Modelo

A pesar de las mejoras, el sistema presenta tres patrones de error sistemáticos que definen su frontera de rendimiento:

- Confusión MEDIUM vs. HARD: La distinción entre estos compuestos en fases medias de carrera es el punto más débil (Recall del 28% en MEDIUM). Al presentar una telemetría agregada similar, el modelo tiende a converger hacia el compuesto duro por su mayor prevalencia histórica.
- Degradación en Secuencias Largas: Se observa una caída del rendimiento del ~70% al ~30% a medida que la simulación avanza hacia el tercer o cuarto stint. Esto sugiere que existen variables exógenas no modeladas (tráfico, incidentes aleatorios, evolución térmica de la pista) que introducen un ruido estructural difícil de capturar con la arquitectura actual.

- Sesgo Conservador en Lluvia: El modelo genera falsos positivos en la clase INTERMEDIATE (Precision del 42%). No obstante, estratégicamente esto se interpreta como un fallo seguro, donde el sistema prefiere advertir de una posible condición adversa antes que ignorar una lluvia real.

7.4. Análisis de Sesgos y Equidad Algorítmica

El estudio de sesgos revela una robustez climática aceptable, con una diferencia de solo 2.3 puntos porcentuales entre el rendimiento en seco y mojado. No obstante, el hallazgo más relevante es el sesgo de consistencia estratégica. El modelo predice con una exactitud significativamente mayor (hasta 0.7) a ciertos pilotos y equipos punteros. Esto indica que el sistema ha aprendido mejor las estrategias altamente estructuradas y lógicas, mientras que su rendimiento decae con pilotos cuyas decisiones son más erráticas o forzadas por circunstancias de carrera externas.

7.5. Propuestas de Trabajo Futuro

Las propuestas de mejora, ya mencionadas en el capítulo de resultados y reforzadas por el análisis de interpretabilidad, se resumen en:

- Enriquecimiento del dataset: incorporar variables físicas de degradación por vuelta permitiría diferenciar con mayor precisión los neumáticos MEDIUM de los HARD.
- Incorporación de mecanismos de atención (Transformers): permitiría al modelo ponderar el contexto global de la carrera, mitigando el olvido en secuencias largas y mejorando la coherencia de stints finales.
- Variables de contexto adicional: telemetría más granular, temperatura de pista y estado del tráfico podrían integrarse para mejorar la discriminación entre estrategias similares.

Estas recomendaciones no solo buscan aumentar la precisión, sino también reforzar la explicabilidad y robustez del modelo, facilitando su uso como herramienta de soporte a la decisión en entornos reales de Fórmula 1.

8. Conclusiones

La investigación desarrollada en este Trabajo Fin de Máster permite dar respuesta a la cuestión central planteada y confirmar la consecución de los objetivos establecidos. A continuación, se sintetizan las conclusiones principales derivadas del estudio:

8.1. Respuesta a la pregunta de investigación

En respuesta a la pregunta de investigación, se concluye que las características globales del circuito y las condiciones climáticas permiten predecir de forma coherente la secuencia estratégica de neumáticos, siempre que se empleen modelos de naturaleza secuencial. La investigación demuestra que el rendimiento estratégico no es una serie de eventos aislados, sino un proceso dinámico donde las condiciones iniciales y el contexto climático condicionan la validez de toda la secuencia posterior. El uso de arquitecturas LSTM ha permitido capturar esta interdependencia, logrando una coherencia en la predicción de la carrera completa sustancialmente superior a los modelos base tradicionales.

8.2. Consecución de objetivos específicos

El éxito del enfoque metodológico se fundamenta en el cumplimiento de los hitos específicos propuestos:

- Construcción del Dataset y Análisis Exploratorio: Se ha logrado estructurar un conjunto de datos robusto a nivel de *stint*, permitiendo identificar patrones críticos de ritmo y degradación que han servido de base para el entrenamiento del modelo.
- Diseño de la Arquitectura Multitarea: La implementación de la red neuronal LSTM para la predicción conjunta (compuesto y duración del stint) ha demostrado ser eficaz, permitiendo que ambas tareas se beneficien de una representación compartida de la dinámica de carrera.
- Simulación Autorregresiva y Métricas Secuenciales: El desarrollo del esquema de simulación ha sido clave para validar el modelo en un escenario real de toma de decisiones. La introducción de métricas como Exact Sequence Accuracy ha proporcionado una visión mucho más honesta y útil del rendimiento estratégico que las métricas de clasificación estándar.
- Interpretabilidad y Sesgos: El uso de técnicas SHAP ha permitido desmitificar el funcionamiento de la red neuronal, confirmando que el modelo otorga una importancia jerárquica lógica a la lluvia y a la longitud del stint. Asimismo, la evaluación de sesgos ha garantizado la robustez del sistema, identificando áreas de mejora en pilotos con patrones menos consistentes.

8.3. Contribución a la reducción de la incertidumbre

El objetivo general de desarrollar un modelo capaz de identificar patrones estratégicos generalizables se ha cumplido satisfactoriamente. Al aprender de secuencias históricamente eficientes, el sistema no solo predice el próximo paso,

sino que ofrece una estructura lógica para la carrera completa. Esta capacidad contribuye directamente a la reducción de la incertidumbre en el muro de boxes, proporcionando una base cuantitativa para la toma de decisiones bajo presión y facilitando la búsqueda de las ganancias marginales que definen el éxito en la Fórmula 1 contemporánea.

8.4. Consideraciones Finales

En definitiva, este trabajo establece una metodología sólida para la aplicación de Deep Learning secuencial en el automovilismo de élite. Se ha demostrado que la integración de información contextual y dependencias temporales es imprescindible para modelar la realidad de la competición, sentando un precedente para futuros sistemas de apoyo a la decisión que busquen optimizar el rendimiento estratégico de forma sistémica y no solo reactiva.

Bibliografía

Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research, 13*(Feb), 281-305.

Brailsford, D. (2015). *Sir Dave Brailsford: The 1% Improvement* (Entrevista). Harvard Business Review.

Cappello, H., & Hoegh, A. (2023). A State-Space Approach to Modeling Tire Degradation in Formula 1 Racing. *Journal of Quantitative Analysis in Sports*.

Clear, J. (2018). *Atomic Habits: An Easy & Proven Way to Build Good Habits & Break Bad Ones*. Avery.

El Haber, G., et al. (2024). Formula 1 Race Winner Prediction Using Random Forest and SHAP Analysis. *IEEE Access*.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735-1780.

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774.

Newey, A. (2017). *How to Build a Car: The Autobiography of the World's Greatest Formula 1 Designer*. HarperCollins.

OpenF1. (2024). *OpenF1 API: A free and open-source API for Formula 1 data*. https://openf1.org

Phillips, D. (2014). A Bayesian model for Formula 1 race strategy. *Journal of Quantitative Analysis in Sports, 10*(3), 309-318.

Red Bull Racing. (2022). *S3 E13: Hannah Schmitz: The trailblazing F1 engineer* [Audio podcast]. En Talking Bull. Oracle Red Bull Racing.

Rodríguez Pinto, M. (2019). *Predicción de resultados de Formula 1 mediante técnicas de Machine Learning* (Trabajo de Fin de Grado). Universidad de Sevilla.

Todd, J. (2020). *Explainable Time Series Prediction of Tyre Energy*. Mercedes-AMG Petronas Formula One Team Technical Reports.

Tulabandhula, T., & Rudin, C. (2014). On the tire change decision in Formula 1 racing. *Proceedings of the Twenty-Eighth AAAI Conference on Artificial Intelligence*, 2968–2974.

Vowles, J. (2019). *James Vowles: The man who makes the calls at Mercedes* (T. Clarkson, Entrevistador). En Beyond the Grid. Formula 1.

Wishal Fatima, S. S., & Johrendt, J. L. (2020). *Deep-Racing: An Embedded Deep Neural Network for Race Strategy Prediction*. arXiv preprint arXiv:2006.XXXX.